Modelos de Regressão Não Linear

GED-16 / PO-216: Análise de Regressão

Profa. Flávia Queiroz

2o. semestre / 2026

Índice

1 Introdução **1**

2 Modelos não lineares (MNL) **3**
2.1 Modelo não-linear linearizável 4
2.2 Modelos intrinsicamente não lineares 4
2.3 Modelos parcialmente lineares 4
2.4 Representações gráficas de modelos de regressão não linear 5
2.5 Mas por que utilizar modelos não lineares? 6
2.5.1 Exemplos de fenômenos e aplicações aeronáuticas 6
2.5.2 Vantagens para uso de modelos não lineares 7

3 Modelos não lineares usuais **8**
3.1 Modelo exponencial 8
3.2 Modelo de crescimento logístico 12
3.3 Modelo de Gompertz 15
3.4 Modelo de Michaelis–Menten 16

4 Inferência em modelos não lineares **20**
4.1 Método dos mínimos quadrados 20
4.2 Máxima verossimilhança 22
4.3 Valores iniciais 23
4.4 Inferências sobre os parâmetros 23
4.4.1 Testes de hipóteses sobre os parâmetros 23
4.4.2 Intervalos de confiança para os parâmetros 25

5 Diagnóstico do modelo **27**
5.1 Exemplo: velocidade de uma reação enzimática 27
5.1.1 Modelo de Michaelis–Menten 29

5.2 Análise dos resíduos 31
5.3 Testes estatísticos 32

6 Qualidade do ajuste e comparação entre modelos 35
6.1 Medidas de adequabilidade do ajuste 39

7 Comparação de modelos não lineares aninhados 42
7.1 Exemplo: comparação de curvas de Michaelis–Menten 43
7.1.1 Síntese da comparação dos três modelos 47

8 Considerações finais 51

Referências 52

E-mail Lattes ITALIO

1 Introdução

O termo regressão é usado para designar a expressão de uma variável dependente Y em função de outras $\mathbf{X}$, consideradas independentes.

Considere, de forma geral,

$$Y_i \mid \mathbf{x}_i = \eta(\mathbf{x}_i, \theta) + \varepsilon_i, \qquad i = 1, \ldots, n,$$

em que:

- $\mathbf{y} = (y_1, \ldots, y_n)^\top$ é o vetor de respostas observadas;
- $\mathbf{x}$ representa as variáveis explicativas;
- $\theta = (\theta_1, \ldots, \theta_p)^\top$ é o vetor de parâmetros desconhecidos;
- $\eta(.)$ é uma função conhecida, mas que depende dos parâmetros θ;
- ε representa a componente aleatória.

No caso clássico de regressão, assume-se frequentemente

$$\varepsilon_i \overset{iid}{\sim} N(0, \sigma^2),$$

de modo que

$$E(Y_i \mid \mathbf{x}_i) = \eta(\mathbf{x}_i, \theta).$$

A Figura 1 apresenta, de forma esquemática, essa relação entre X e a distribuição condicional de Y. A relação impõe que qualquer Y_i possui distribuição gaussiana, com mesma variância e, média que depende do respectivo x_i pela relação

$$E[Y_i|x_i] = \mu_i = \beta_0 + \beta_1 x_i.$$

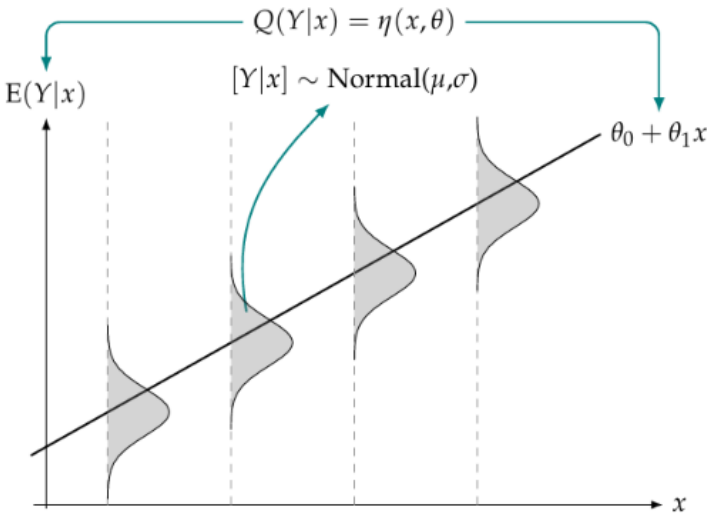


Figura 1: Modelo de regressão gaussiana (linear simples). Fonte: Zeviani et al. (2013)

Nesse caso, temos uma regressão linear, caracterizada por pressupor uma distribuição gaussiana com homocedasticidade, ligação identidade com a E[Y|x] e função linear dos parâmetros.

Contudo, cada uma dessas premissas pode ser ajustada na formulação de modelos alternativos. Em muitos problemas de regressão, por exemplo, a relação entre a variável resposta e as variáveis explicativas não pode ser representada adequadamente por uma combinação linear dos parâmetros. Nesses casos, possíveis alternativas envolvem adotar:

i. uma estrutura polinomial, tal como uma forma quadrática $\mu_i = \beta_0 + \beta_1 x_i + \beta_2 x_i^2$;

ii. uma função de ligação não linear, tal como $\mu_i = e^{(\beta_0 + \beta_1 x_i)}$; ou

iii. uma estrutura intrinsicamente não linear.

i Modelo linear × modelo não linear

Um modelo é **linear nos parâmetros** quando pode ser escrito como

$$E(Y_i \mid \mathbf{x}_i) = \beta_0 + \beta_1 x_{i1} + \cdots + \beta_p x_{ip}.$$

Já em um modelo não linear, os parâmetros aparecem dentro de funções como exponenciais,

potências, razões ou outras estruturas não lineares. Por exemplo,

$$E(Y_i \mid x_i) = \frac{\alpha x_i}{\beta + x_i}$$

é **não linear nos parâmetros** $V_{\max}$ e K_m.
É importante observar que "não linear" se refere, nesse contexto, principalmente à **forma como os parâmetros aparecem no modelo**, e não simplesmente ao fato de a curva observada não ser uma reta.

2 Modelos não lineares (MNL)

Os modelos de regressão não linear são frequentemente utilizados para descrever relações entre uma resposta contínua e uma ou mais variáveis explicativas quando a **função da média não é linear nos parâmetros**. Por exemplo, situções que podem representar *o crescimento de um indivíduo em função da idade, a concentração de um fármaco no organismo ao longo do tempo ou a resposta de um material à variação de temperatura.*

Para esse tipo de situações, a distribuição Gaussiana representa bem o comportamento da resposta, embora outras distribuições possam ser mais apropriadas dependendo da natureza dos dados e das hipóteses adotadas para o modelo.

Por definição, um modelo é considerado **não linear** quando pelo menos uma das derivadas parciais do vetor de valores esperados η em relação aos parâmetros θ depende explicitamente desses mesmos parâmetros.

Considere dois modelos e suas derivadas em relação aos seus respectivos parâmetros, conforme Tabela 1.

Tabela 1: Tabela comparativa dos modelos e suas derivadas

Modelo Polinomial Quadrático	Modelo de Decaimento Exponencial
$\eta(x, \beta) = \beta_0 + \beta_1 x + \beta_2 x^2$	$\eta(x, \beta) = \beta_0 e^{-\beta_1 x}$ (1)
$\frac{\partial \eta}{\partial \beta_0} = 1 \frac{\partial \eta}{\partial \beta_1} = x \frac{\partial \eta}{\partial \beta_2} = x^2$ *Apenas constantes e variáveis conhecidas, livres de parâmetros*	$\frac{\partial \eta}{\partial \beta_0} = e^{-\beta_1 x} \frac{\partial \eta}{\partial \beta_1} = -\beta_0 x e^{-\beta_1 x}$ *Envolvem os parâmetros estruturais do modelo*

O Modelo Linear Quadrático é definido como sendo um modelo linear nos parâmetros, pois ao avaliar as derivadas parciais para sua equação, observa-se que nenhuma delas envolve os

parâmetros do modelo, contendo apenas quantidades conhecidas (1, x e x^2). Por outro lado, ao analisar as derivadas parciais para a equação da direita, nota-se que os resultados das derivadas envolvem parâmetros estruturais do modelo. Portanto, conclui-se que o Modelo Exponencial Assintótico caracteriza um modelo não linear.

2.1 Modelo não-linear linearizável

A literatura estatística também contempla classificações intermediárias. Um modelo é dito **linearizável** se puder ser transformado em um modelo linear por meio de uma transformação matemática ou reparametrização adequada. Um exemplo clássico é a função:

$$\eta(x, \theta) = e^{(\theta_0 + \theta_1 x)}$$

que, ao se aplicar a transformação logarítmica, assume a representação linear:

$$log(\eta(x, \theta)) = \theta_0 + \theta_1 x.$$

2.2 Modelos intrinsicamente não lineares

Em contrapartida, os modelos que não podem ser transformados em modelos lineares por meio de nenhuma manipulação algébrica ou mudança de escala (como aplicação de logaritmos, inversas ou raízes) são classificados como **intrinsicamente não lineares**. Um exemplo é a Equação 1 ou curvas de crescimento complexas (como o modelo logístico ou de Gompertz, que veremos mais à frente).

2.3 Modelos parcialmente lineares

Uma classificação útil dos MNL é quanto ao número de parâmetros que ocorrem de forma linear. Nota-se que nas derivadas parciais da Equação 1, a derivada referente a θ_a não depende de θ_a. O mesmo comportamento, contudo, não se repete para os demais parâmetros. Por essa razão, define-se que o modelo é **parcialmente linear em** θ_a, visto que, ao fixar os demais parâmetros como constantes conhecidas, a estrutura reduz-se a um modelo linear.

2.4 Representações gráficas de modelos de regressão não linear

A Figura 2 apresenta, de forma esquemática, a relação não-linear entre X e a distribuição condicional de . A relação impõe que:

(i) qualquer Y_i possui distribuição gaussiana, com variância constante, $Y_i|x_i \sim N(\mu_i, \sigma^2)$;

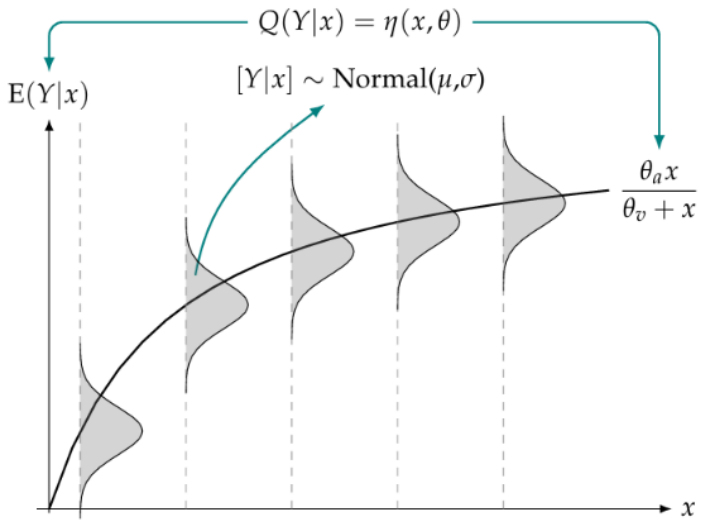


Figura 2: Modelo de regressão não linear gaussiano. Fonte: Zeviani et al. (2013)

(ii) a relação entre os parâmetros não é liner, $E[Y_i|x_i] = \mu_i = g(\beta_0, \beta_1, x_i) = \frac{\theta_a x}{\theta_v + x_i}$.

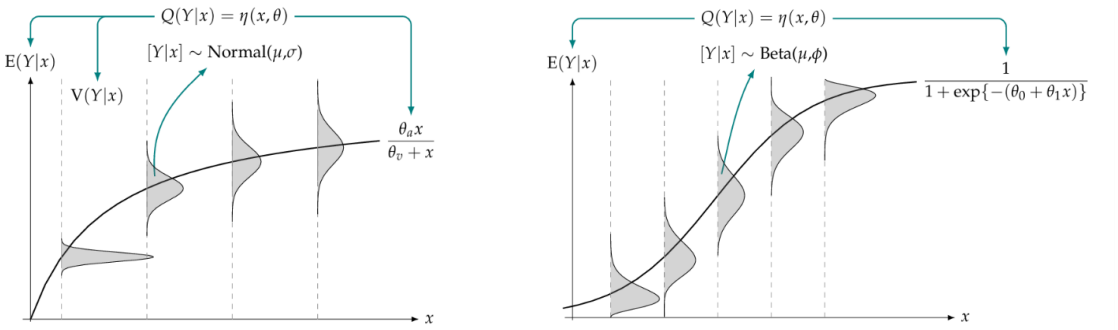
O modelo apresentado, $\frac{\theta_a x}{\theta_v + x_i}$, pode ser dito um modelo não-linear gaussiano de Y como função de x ou, equivalentemente, um modelo linear generalizado com distribuição gaussiana, função de ligação inversa $\mu_i = (\beta_0 + \beta_1 x_i^*)^{-1}$ (em que $\beta_0 = 1/\theta_a$ e $\beta_1 = \theta_v/\theta_a$) e covariável $x^* = 1/x$. A principal diferença em relação ao modelo linear está na forma como os parâmetros entram na função média.

Outros dois casos de modelos não-lineares são apresentados a seguir. Na Figura 3 (a) tem-se que a variância de Y se altera para diferentes valores de x, segundo uma função que depende dos valores de x.

Já o modelo apresentado na Figura 3 (b) se enquadra na classe dos GLMs, mas pode ser alternativamente formulado como um modelo beta não linear de regressão, visto que a esperança condicional $E[Y|x]$ associa-se a x por meio de uma função não linear dos coeficientes do vetor β. Sob a suposição de que Y obedece a uma distribuição beta, os desvios resultantes exibem comportamento heterocedástico e graus de assimetria que oscilam conforme o valor de x.

2.5 Mas por que utilizar modelos não lineares?

A utilização de um **modelo não linear (MNL)** é particularmente apropriada quando há conhecimento prévio, teórico ou empírico, que sustenta uma forma funcional específica para a relação entre a variável resposta e as variáveis explicativas. Nesses casos, a escolha do modelo



(a) Regressão não linear gaussiana heterocedástica (b) Regressão beta

Figura 3: Modelo de (a) regressão não linear gaussiano heterocedástico, à esquerda e (b) regressão beta, à direita. Fonte: Zeviani et al. (2013).

não se baseia apenas na capacidade de ajuste aos dados, mas também em uma estrutura que procura representar o comportamento esperado do fenômeno.

Em aplicações de Engenharia Aeronáutica, por exemplo, relações de **crescimento, decaimento, saturação, resposta a uma concentração ou dose, aprendizagem e aproximação a limites** podem surgir em diferentes contextos:

> ⚠ Seção em desenvolvimento
>
> Este material está em construção, com adaptações para aplicações na área aeronáutica. Conteúdos, exemplos e interpretações ainda estão sendo revisados; contribuições são bem-vindas.

2.5.1 Exemplos de fenômenos e aplicações aeronáuticas

Tabela 2: Exemplos de fenômenos e possíveis aplicações de modelos não lineares na área aeronáutica.

Fenômeno	Possível aplicação
Crescimento ou decaimento	Resistência de selantes de tanques de combustível ao longo do tempo de ensaio
Saturação	Absorção de umidade por materiais compósitos em função do tempo
Dose–resposta	Efetividade de tratamentos superficiais em ligas metálicas em função da concentração de eletrólito
Crescimento acumulado	Complexidade de software embarcado ao longo das gerações de projetos de aeronaves

Fenômeno	Possível aplicação
Cinética química	Grau de polimerização de resinas epóxi em função do tempo de ciclo em autoclave
Relação concentração–resposta	Sinal elétrico de sensores de oxigênio em função da concentração do gás
Crescimento com estabilização	Deformação acumulada de componentes metálicos em função do número de ciclos de ensaio
Aproximação a um limite	Eficiência volumétrica de compressores de turbofans em função da altitude de voo
Aprendizagem	Tempo de montagem de subconjuntos de asas em função do número acumulado de unidades produzidas

Nessas situações (Tabela 2), uma função não linear pode representar diretamente a **forma esperada da relação**, e seus parâmetros ou funções deles podem assumir **interpretação prática**. Além disso, quando a estrutura escolhida é adequada, o modelo pode oferecer uma **representação parcimoniosa do fenômeno**, isto é, até mesmo comportamentos complexos podem ser descritos por um número relativamente pequeno de parâmetros com significado próprio.

2.5.2 Vantagens para uso de modelos não lineares

Os MNL apresentam algumas características que os distinguem de uma representação linear puramente empírica:

- **Estrutura mecanística:** a forma funcional pode ser fundamentada em princípios físicos, químicos ou biológicos, ou em conhecimento prévio sobre o fenômeno;
- **Parâmetros interpretáveis:** os parâmetros podem representar grandezas de interesse científico, como taxas de crescimento ou decaimento, valores assintóticos e tempos característicos;
- **Parcimônia do modelo:** uma função adequada pode representar o comportamento de interesse com poucos parâmetros, sem exigir muitos termos ou uma função linear por partes.
- **Uso do conhecimento prévio:** informações disponíveis sobre o fenômeno podem ser incorporadas diretamente à especificação do modelo;
- **Extrapolação:** quando a forma da curva é sustentada por conhecimento teórico ou científico, o modelo pode orientar previsões além do intervalo observado. Essas previsões, porém, dependem da validade da forma funcional fora da região em que há dados.

Essas características também impõem limitações. A estimação dos parâmetros geralmente é feita por **procedimentos iterativos**, que podem depender de valores iniciais e apresentar

dificuldades de convergência. Além disso, resultados inferenciais podem depender de **aproximações assintóticas, especialmente em amostras pequenas**. A especificação do modelo também exige conhecimento suficiente sobre o fenômeno para que a forma funcional escolhida seja plausível.

i Em síntese

O uso de um MNL é especialmente interessante quando existe uma razão para acreditar que a relação entre as variáveis possui uma **estrutura funcional específica**.

conhecimento sobre o fenômeno $\longrightarrow$ forma funcional $\longrightarrow$ parâmetros interpretáveis

O objetivo, portanto, não é simplesmente substituir um modelo linear por uma curva mais flexível, mas utilizar uma estrutura não linear quando ela oferece uma representação adequada e cientificamente interpretável do fenômeno.

---

3 Modelos não lineares usuais

Os modelos não lineares podem assumir diferentes formas funcionais, escolhidas de acordo com o comportamento esperado da relação entre a variável resposta e as variáveis explicativas. A escolha de uma determinada forma funcional requer, entretanto, a compreensão do significado prático dos seus parâmetros e de como eles se relacionam com o fenômeno investigado. A seguir, são apresentados alguns modelos usuais, destacando-se sua forma, a interpretação dos parâmetros e os tipos de fenômenos que podem representar.

3.1 Modelo exponencial

Um dos modelos não lineares mais simples é o modelo exponencial. Sua expressão simplificada é dada por:

$$Y_i = \alpha e^{\beta x_i} + \epsilon_i,$$

em que, $i = 1, 2, \ldots, n$;
Y_i é a i-ésima observação da variável dependente;
x_i é a i-ésima observação da variável independente;
α é o valor esperado da variável resposta quando $x_i = 0$;
β é o parâmetro associado à taxa de crescimento ou decaimento exponencial, sendo que $\beta > 0$

caracteriza crescimento e $\beta < 0$, decaimento;
ϵ_i é o erro aleatório associado à i-ésima observação, sendo $\epsilon_i \sim N(0, \sigma^2)$.

! Importante

O modelo exponencial é amplamente utilizado para descrever processos de crescimento ou decaimento nos quais a taxa de variação da variável é proporcional ao seu valor atual. Essa característica típica do crescimento/decrescimento exponencial permite representar fenômenos que se aceleram ou se reduzem ao longo do tempo de acordo com a magnitude observada da variável.
Por exemplo, considerando a função

$$y = \alpha e^{\beta x},$$

tem-se que sua derivada em relação a x é dada por

$$\frac{dy}{dx} = \beta y.$$

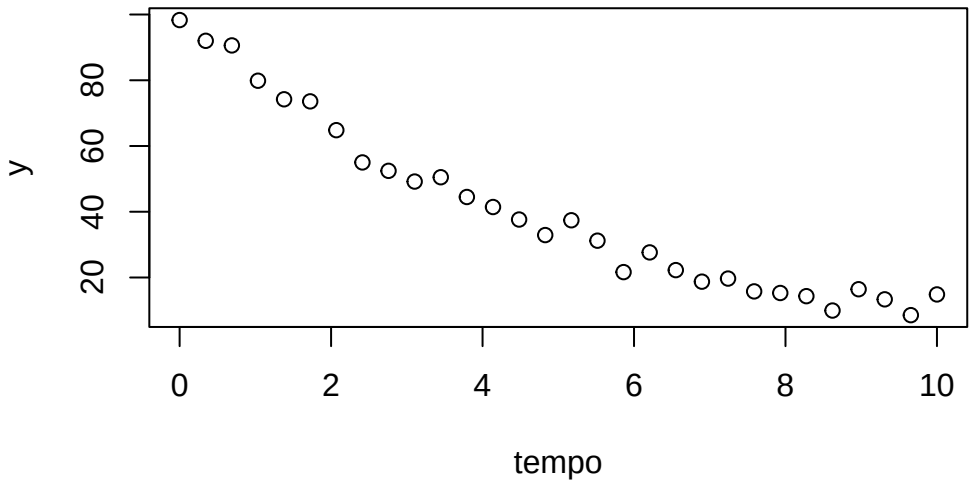
Isso mostra que a taxa de variação $\frac{dy}{dx}$ é proporcional ao próprio valor y. Em outras palavras, quanto maior for o valor da variável, maior será sua taxa de crescimento. Da mesma forma, durante um processo de decaimento, a redução ocorre de maneira proporcional ao valor existente naquele momento.

Exemplo: degradação de uma propriedade de um material
Suponha que uma propriedade física de um material seja medida ao longo do tempo de exposição a uma determinada condição ambiental. Assim, temos um modelo de decaimento de modo que

$$E(Y_i \mid t_i) = \alpha e^{-\beta t_i}, \qquad \alpha > 0, \quad \beta > 0.$$

Nesse caso α representa o valor esperado da propriedade no instante inicial e β controla a velocidade de degradação.

```
set.seed(123)
tempo <- seq(0, 10, length.out = 30)
y <- 100 * exp(-0.22 * tempo) + rnorm(30, 0, 3)
dados_exp <- data.frame(tempo, y)
plot(y~tempo)
```



O modelo pode ser ajustado por mínimos quadrados não lineares, pela função `nls()` do R. Para o ajuste, os valores iniciais fornecidos ao nls() definem o ponto a partir do qual o procedimento iterativo inicia a busca pelos parâmetros.

```
ajuste_exp <- nls(
  y ~ alpha * exp(-beta * tempo),
  data = dados_exp,
  start = list(alpha = 99, beta = 0.2)
)
summary(ajuste_exp)
```

```
Formula: y ~ alpha * exp(-beta * tempo)

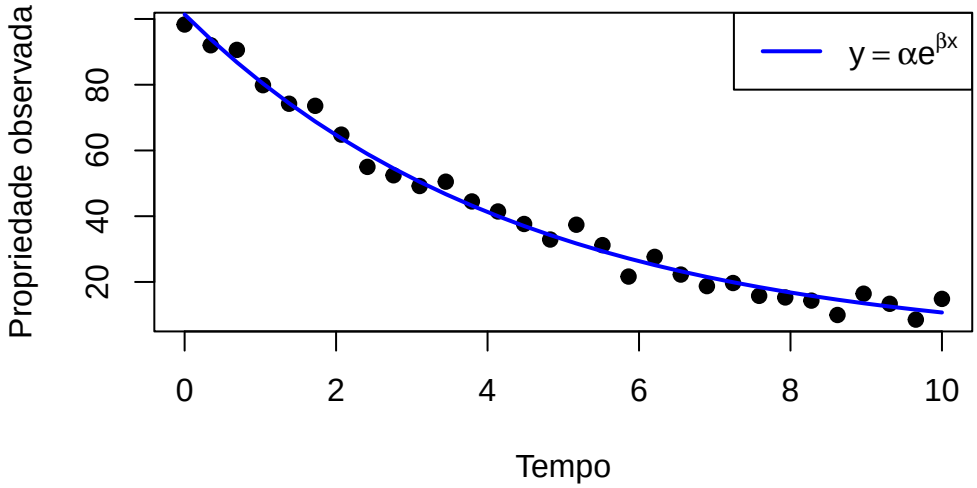
Parameters:
       Estimate Std. Error t value Pr(>|t|)
alpha 1.014e+02  1.583e+00   64.05   <2e-16 ***
beta  2.248e-01  5.617e-03   40.01   <2e-16 ***
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 2.952 on 28 degrees of freedom

Number of iterations to convergence: 3
```

```
Achieved convergence tolerance: 9.238e-06
```

```r
plot(dados_exp$tempo, dados_exp$y,
     pch = 19,
     xlab = "Tempo",
     ylab = "Propriedade observada")
lines(tempo, predict(ajuste_exp), col = "blue",lwd = 2)
legend("topright",
       legend = expression(y == alpha * e^{beta * x}),
       col = "blue",
       lty = 1,
       lwd = 2)
```



Por que não simplesmente transformar o modelo?

Alguns modelos não lineares podem ser transformados em modelos lineares. Por exemplo, tomando logaritmos em um modelo exponencial, obtém-se

$$\log(Y_i) = \log(\alpha) + \beta x_i + \text{erro transformado.}$$

Essa transformação pode facilitar a estimação, mas altera a estrutura dos erros e, consequentemente, a interpretação estatística do modelo.

Quando a forma não linear é cientificamente justificável, o ajuste diretamente na escala original pode ser preferível, principalmente quando o interesse está na interpretação dos parâmetros na escala original da resposta.

3.2 Modelo de crescimento logístico

O **modelo logístico** foi proposto em 1838, por Pierre François Verhulst para descrever o crescimento de populações humanas. É um dos modelos não lineares mais utilizado para representar um processo cujo crescimento inicialmente é acelerado, seguido de desaceleração e aproximação assintótica a um limite superior α. Sua expressão simplificada é dada por:

$$Y_i = \frac{\alpha}{1 + e^{\kappa(\beta - x_i)}} + \epsilon_i,$$

em que, $i = 1, 2, ..., n$; Y_i é a i-ésima observação da variável dependente; x_i é a i-ésima observação da variável independente; α é o valor assintótico, ou seja, o valor esperado para o crescimento máximo do objeto em estudo, quando xi $\rightarrow \infty$; β é a abscissa do ponto de inflexão, ou seja, a partir dele o crescimento é desacelerado; κ é um índice associado à "velocidade de" crescimento, ou seja, quanto maior for seu valor, menos tempo será necessário para o objeto em estudo atingir o valor assintótico α; ϵ_i é o erro aleatório associado à $i-$ésima observação, sendo $ _i N(0, ^2).

No ponto $x_i = \beta$, tem-se $Y_i = \alpha/2 \approx 0,5\alpha$: Nesse ponto, a curva deixa de ser **côncava para cima** e passa a ser **côncava para baixo**, sendo a curva sigmoidal simétrica em relação ao ponto de inflexão. É também onde a taxa de crescimento é máxima.

Aplicações
O modelo pode representar, por exemplo:

- crescimento populacional;
- crescimento de biomassa;
- adoção acumulada de uma tecnologia;
- evolução de uma variável física com saturação;
- processos sujeitos a uma capacidade máxima.

Exemplo: Adoção de uma tecnologia
Suponha que uma nova tecnologia tenha sido adotada para dar continuidade a um sistema existente. Ao longo dos meses, a adoção tende a aumentar inicialmente de forma mais lenta, apresentar um período de crescimento acelerado e, posteriormente, aproximar-se de um nível de estabilização. Esse comportamento pode ser representado por um **modelo de crescimento logístico**, adequado para situações em que o crescimento ocorre de forma limitada a um valor máximo.

Nesse exemplo, os dados serão simulados a partir de uma curva de crescimento logístico. A resposta observada é composta pela curva teórica de adoção acrescida de um erro aleatório, assumido, na simulação, como normalmente distribuído, com média zero e desvio-padrão igual a 3.
O ajuste do modelo pode ser realizado por meio da função `nls()`, que utiliza, por padrão, o **algoritmo de Gauss–Newton** para obter as estimativas dos parâmetros por mínimos quadrados não lineares.

```r
set.seed(123)
tempo <- seq(0, 20, length.out = 40)
y <- 100 /
  (1 + exp(0.45 * (10 - tempo))) +
  rnorm(40, 0, 3)
dados_log <- data.frame(tempo, y)

#O ajuste pode ser realizado por:
ajuste_log <- nls(
  y ~ alpha / (1 + exp(k * (beta - tempo))),
  data = dados_log,
  start = list(alpha = 100, k = 0.4, beta = 10)
)
summary(ajuste_log)
```

```
Formula: y ~ alpha/(1 + exp(k * (beta - tempo)))

Parameters:
       Estimate Std. Error t value Pr(>|t|)
alpha 102.17893    1.21285   84.25   <2e-16 ***
k       0.42332    0.01493   28.36   <2e-16 ***
beta   10.20873    0.10683   95.56   <2e-16 ***
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

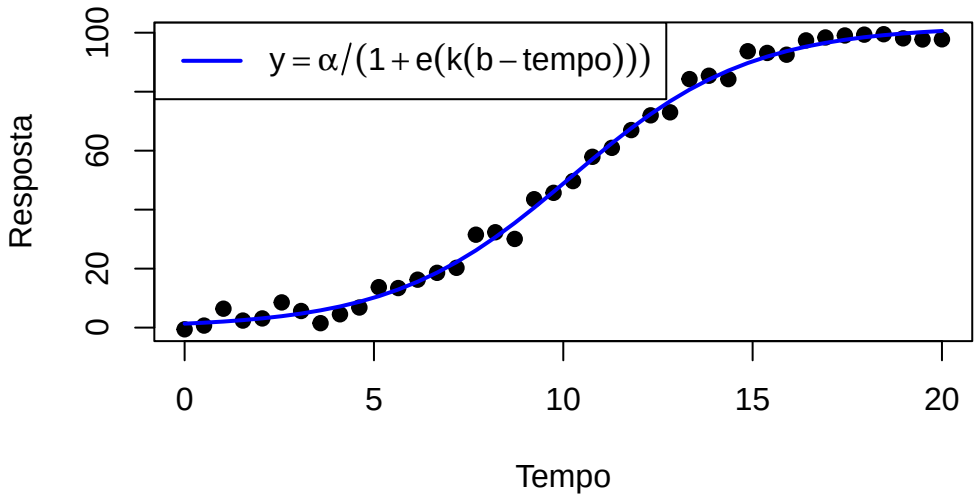
Residual standard error: 2.599 on 37 degrees of freedom

Number of iterations to convergence: 4
Achieved convergence tolerance: 2.52e-06
```

```r
# Plotando os dados:
plot(dados_log$tempo, dados_log$y,
     pch = 19,
     xlab = "Tempo",
     ylab = "Resposta")

# Adicionando o modelo ajustado e legenda:
lines(dados_log$tempo,
      predict(ajuste_log),
      col = "blue",
      lwd = 2)

# Adicionando a legenda:
legend("topleft",
       legend = expression(
         y==alpha / (1 + e(k(b - tempo)))
       ),
       col = "blue",
       lty = 1,
       lwd = 2)
```



3.3 Modelo de Gompertz

O **modelo de Gompertz** é outra função sigmoidal utilizada para representar crescimento com aproximação a um limite superior K. Ele foi desenvolvido por Gompertz, em 1825, para a análise de tábuas de mortalidade. Posteriormente, o modelo foi empregado na construção de curvas de crescimento e, desde então, é frequentemente utilizado na modelagem de processos de crescimento em contextos econômicos e biológicos (crescimento de células tumorais etc.). A forma geral do modelo é tal que:

$$Y_i = \alpha e^{-e^{\kappa(\beta - x_i)}} + \epsilon_i,$$

Os parâmetros desse modelo possuem a mesma interpretação atribuída ao modelo Logístico. Além disso, a assíntota horizontal continua sendo descrita pela reta $y = \alpha$, conservando o mesmo significado na representação do fenômeno.

A principal diferença é que a curva de Gompertz é **assimétrica em torno do ponto de inflexão**, permitindo representar situações em que o crescimento é mais rápido em uma das regiões da curva. Nesse caso, também temos $x_i = \beta$ como ponto de inflexão, **mas o valor da função nesse ponto é diferente**:

$$f(\beta) = \alpha e^{-e^0} = \alpha e^{-1} = \frac{\alpha}{e} \approx 0,368\alpha.$$

Aplicações
Entre as aplicações estão:

- crescimento de tumores;
- crescimento de populações;
- crescimento microbiano;
- desenvolvimento de organismos;
- crescimento do risco de morte ao longo da vida.

A escolha entre os Modelos de Crescimento Logístico e de Gompertz deve considerar tanto o comportamento esperado do fenômeno quanto a adequação do modelo aos dados. Veja os gráficos dispostos em Figura 4:

3.4 Modelo de Michaelis–Menten

O **modelo de Michaelis–Menten** tem origem nos estudos de cinética enzimática desenvolvidos por Leonor Michaelis e Maud Leonora Menten, publicados em 1913, para investigar a relação entre a concentração de substrato e a velocidade de reações catalisadas por enzimas. O modelo é utilizado para representar relações de saturação, nas quais a resposta aumenta com a variável explicativa, mas tende progressivamente a um limite superior.

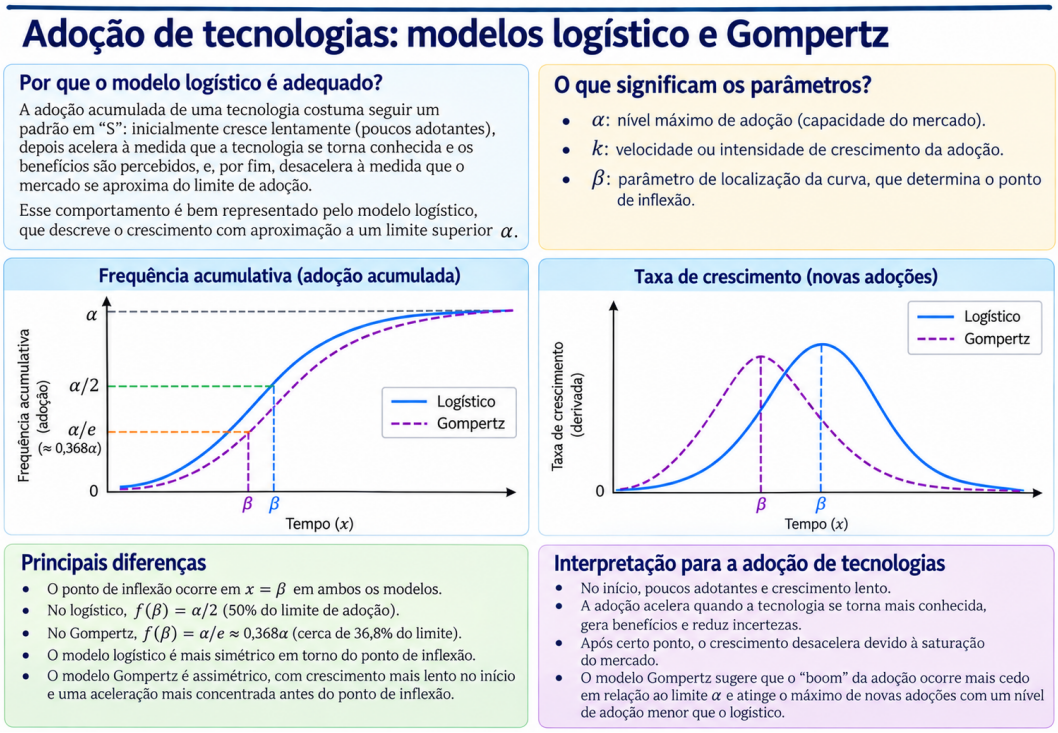


Figura 4: Comparação Modelos Logístico e Gompertz.

Sua expressão simplificada pode ser escrita como:

$$Y_i = \frac{\alpha x_i}{\beta + x_i} + \epsilon_i,$$

em que, $i = 1, 2, \ldots, n$;
Y_i é a i-ésima observação da variável dependente;
x_i é a i-ésima observação da variável independente;
α é o valor assintótico superior da resposta, isto é, o valor para o qual a resposta esperada tende quando $x_i \to \infty$;
β é o valor de x_i para o qual a resposta esperada corresponde à metade do valor assintótico α;
ϵ_i é o erro aleatório associado à i-ésima observação, sendo $\epsilon_i \sim N(0, \sigma^2)$.

Para valores pequenos da variável explicativa, a resposta aumenta de forma mais acentuada. À medida que x_i aumenta, a taxa de crescimento da resposta diminui progressivamente, aproximando-se assintoticamente de α. Em outras palavras, o modelo de saturação Michaelis–Menten **não apresenta forma sigmoidal nem ponto de inflexão**: para $\alpha > 0$ e $\beta > 0$, a curva é crescente e côncava para baixo em todo o domínio $x_i > 0$.

Os dois modelos de saturação, Logístico e de Gompertz possuem uma fase inicial de aceleração seguida de desaceleração; já o modelo de Michaelis–Menten apresenta desaceleração desde o início. Isso explica geometricamente por que os dois primeiros possuem ponto de inflexão e Michaelis–Menten não.

i Modelo de Michaelis–Menten

Na formulação original da cinética enzimática, o modelo é usualmente expresso como

$$v = \frac{V_{\max} S}{K_m + S},$$

em que v representa a velocidade da reação, S é a concentração de substrato, $V_{\max}$ é a velocidade máxima da reação e K_m é a constante de Michaelis. Quando $S = K_m$, tem-se

$$v = \frac{V_{\max} K_m}{K_m + K_m} = \frac{V_{\max}}{2}.$$

Assim, K_m corresponde à concentração de substrato na qual a velocidade da reação atinge metade de $V_{\max}$.

Aplicações
Além da aplicação clássica em cinética enzimática, a forma funcional de Michaelis–Menten pode representar fenômenos caracterizados por crescimento com saturação, tais como:

- velocidade de reações enzimáticas em função da concentração de substrato;
- processos de absorção ou captação com capacidade limitada;

- respostas biológicas à disponibilidade de nutrientes;
- processos nos quais incrementos sucessivos da variável explicativa produzem aumentos cada vez menores na resposta.

Exemplo: Considere uma reação enzimática na qual uma enzima transforma um determinado substrato em produto. À medida que a concentração de substrato aumenta, espera-se que a velocidade da reação também aumente. Entretanto, após determinado nível de concentração, o aumento da velocidade tende a ser cada vez menor, pois os sítios ativos (local de processamento) disponíveis na enzima vão sendo progressivamente ocupados.

Em uma aplicação tecnológica, pode-se pensar, por exemplo, em uma enzima ou outro biocatalisador responsável pela degradação de um determinado composto: a concentração do composto corresponde a (S), enquanto (v) representa a velocidade de sua degradação.

```r
set.seed(123)
S <- seq(0.2, 20, length.out = 35)
v <- (8 * S) / (3 + S) +
  rnorm(length(S), 0, 0.15)
dados_mm <- data.frame(S, v)

# Ajustando o modelo de Michaelis--Menten:
ajuste_mm <- nls(
  v ~ Vmax * S / (Km + S),
  data = dados_mm,
  start = list(Vmax = 8, Km = 3)
)
summary(ajuste_mm)
```

```
Formula: v ~ Vmax * S/(Km + S)

Parameters:
     Estimate Std. Error t value Pr(>|t|)
Vmax  7.95220    0.07729  102.89   <2e-16 ***
Km    2.91437    0.11522   25.29   <2e-16 ***
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

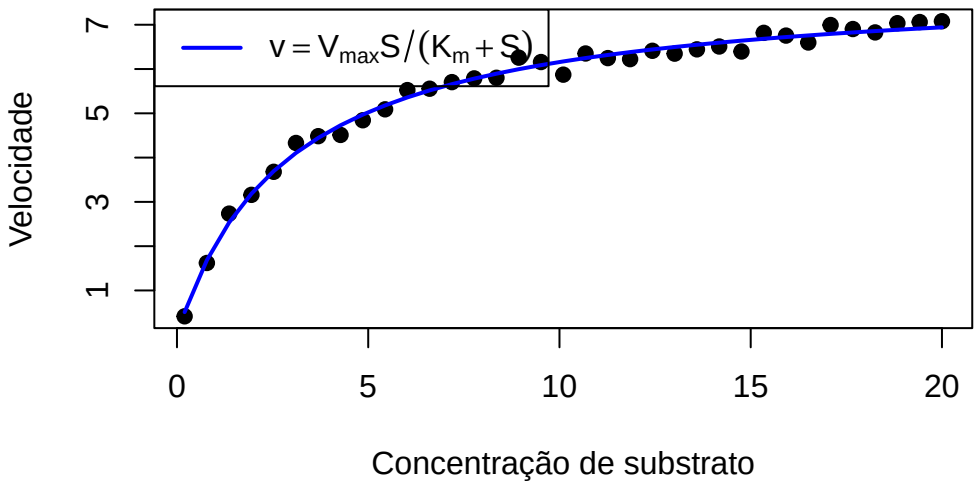
Residual standard error: 0.143 on 33 degrees of freedom

Number of iterations to convergence: 2
Achieved convergence tolerance: 9.929e-07
```

```r
# Plotando os pontos:
plot(dados_mm$S, dados_mm$v,
     pch = 19,
     xlab = "Concentração de substrato",
     ylab = "Velocidade")

# Adicionando a curva ajustada:
lines(dados_mm$S,
      predict(ajuste_mm),
      col = "blue",
      lwd = 2)

# Adicionando a legenda:
legend("topleft",
       legend = expression(
         v == V[max]*S/(K[m] + S)
       ),
       col = "blue",
       lty = 1,
       lwd = 2)
```



Os exemplos apresentados mostram diferentes formas de comportamento que podem ser repre-

sentadas por modelos não lineares: **crescimento ou decaimento exponencial, crescimento com saturação, crescimento assimétrico e relações de saturação**. A escolha da forma funcional deve estar associada ao fenômeno estudado e à interpretação que se deseja atribuir aos parâmetros.

A questão de **como estimar os parâmetros desses modelos**, incluindo a escolha dos valores iniciais e os métodos iterativos empregados na estimação, será discutida no próximo capítulo.

4 Inferência em modelos não lineares

A partir de uma amostra de observações de Y, associadas aos respectivos valores observados de $\mathbf{X}$, busca-se estimar as quantidades desconhecidas θ e σ^2, que são os parâmetros do modelo.

Em um modelo de regressão linear múltipla, o vetor de médias condicionais é dado por uma combinação linear dos parâmetros:

$$E(\mathbf{Y} \mid \mathbf{X}) = \mathbf{X}\theta$$

e, temos que a matriz de derivadas da sua função média em relação aos parâmetros coincide com a matriz de planejamento $\mathbf{X}$.

Já na regressão não linear, como a função média $\eta(\mathbf{X}, \theta)$ é não linear nos parâmetros θ, não é possível obter diretamente os estimadores pelos métodos da regressão linear. Para contornar isso, utiliza-se a matriz Jacobiana para construir uma aproximação linear local do modelo. Essa aproximação local é fundamental para os procedimentos iterativos de estimação e inferência.

Os elementos da matriz Jacobiana correspondem às derivadas parciais da função média em relação aos parâmetros, que **geralmente dependem tanto das variáveis explicativas quanto dos parâmetros do modelo**.

$$\mathbf{F}_0 = \mathbf{J}(\theta) = \begin{bmatrix} \frac{\partial \eta(x_1,\theta_0)}{\partial \theta_1} & \frac{\partial \eta(x_1,\theta_0)}{\partial \theta_2} & \cdots & \frac{\partial \eta(x_1,\theta_0)}{\partial \theta_p} \\ \frac{\partial \eta(x_2,\theta_0)}{\partial \theta_1} & \frac{\partial \eta(x_2,\theta_0)}{\partial \theta_2} & \cdots & \frac{\partial \eta(x_2,\theta_0)}{\partial \theta_p} \\ \vdots & \vdots & \ddots & \vdots \\ \frac{\partial \eta(x_n,\theta_0)}{\partial \theta_1} & \frac{\partial \eta(x_n,\theta_0)}{\partial \theta_2} & \cdots & \frac{\partial \eta(x_n,\theta_0)}{\partial \theta_p} \end{bmatrix}$$

4.1 Método dos mínimos quadrados

Em modelos não lineares, sob a suposição de efeitos fixos, erros independentes, distribuição Gaussiana e variância constante, a estimação dos parâmetros da função média pode ser realizada pelo método dos mínimos quadrados.

Os estimadores dos parâmetros são obtidos pela minimização da soma dos quadrados das diferenças entre os valores observados y_i e os valores ajustados pelo modelo,

$$SQR(\theta) = \sum_i [y_i - \eta(x_i, \theta)]^2 . \tag{2}$$

Na regressão não linear, a função média $\eta(X, \theta)$ não é linear nos parâmetros θ, impossibilitando a obtenção de estimadores por meio das equações normais dos mínimos quadrados lineares. Dessa forma, a estimação dos parâmetros requer procedimentos iterativos, nos quais a função é linearizada localmente por expansões de Taylor.

Assim, para estimar os parâmetros do modelo via Mínimos Quadrados Ordinários (ou Gauss-Newton), recorremos à série de Taylor de primeira ordem em torno de um vetor de parâmetros de referência θ_0:

$$\eta(x, \theta) \approx \eta(x, \theta_0) + \sum_{j=1}^{p} \frac{\partial \eta(x, \theta_0)}{\partial \theta_j} (\theta_j - \theta_{j0})$$

Ao expandir a função para todas as n observações do conjunto de dados, chegamos à matriz de derivadas parciais, que é a matriz Jacobiana do modelo. Em notação matricial, temos:

$$\eta(\theta) \approx \eta(\theta_0) + \mathbf{F}_0(\theta - \theta_0)$$

Essa matriz $\mathbf{F}_0$ assume o papel da matriz de delineamento X da regressão linear e desempenha papel fundamental na atualização das estimativas e na convergência do algoritmo de ajuste.

O vetor de correção dos parâmetros ($\delta = \theta - \theta_0$) é obtido resolvendo a equação normal adaptada:

$$\delta = (\mathbf{F}_0^T \mathbf{F}_0)^{-1} \mathbf{F}_0^T [Y - \eta(x, \theta_0)]$$

Note a semelhança direta com o estimador de mínimos quadrados clássico $\widehat{\beta} = (\mathbf{X}^T\mathbf{X})^{-1}\mathbf{X}^T\mathbf{Y}$, onde o vetor de "respostas ajustadas" passa a ser o vetor de resíduos atualizados da função não linear.

Como a matriz de derivadas depende de θ e o valor real é desconhecido, o processo ocorre por aproximações sucessivas utilizando um chute inicial $\theta^{(0)}$. A cada iteração t, o algoritmo:

(1) calcula a matriz Jacobiana no vetor de parâmetros atual $\theta^{(t)}$;
(2) resolve-se o sistema de equações normais para encontrar o incremento (correção)$\delta^{(t)}$;
(3) atualiza-se o vetor de parâmetros para a próxima iteração somando o incremento, $\theta^{(t+1)} = \theta^{(t)} + \delta^{(t)}$;
(4) o processo repete os passos de 1 a 3 iterativamente até que a diferença entre $\theta^{(t+1)}$ e $\theta^{(t)}$ atinja algum critério de convergência estabelecido.

Conforme os parâmetros são atualizados a cada passo iterativo (por exemplo, $\theta^{(t+1)} = \theta^{(t)} + \delta$), a matriz de derivadas é recalculada nos novos pontos.

Em modelos não lineares, o método dos mínimos quadrados constitue uma abordagem de estimação muito utilizada. Já o método da máxima verossimilhança fornece uma formulação mais geral, baseada na distribuição assumida para os dados.

Função nls() no R

No R, a função `nls()` realiza ajuste por mínimos quadrados não lineares e, em sua configuração padrão, utiliza uma estratégia baseada em Gauss–Newton.
Como o processo iterativo inicia-se com a especificação de valores iniciais para os parâmetros $\theta_0, \theta_1, \ldots, \theta_p$, esses valores podem ser definidos com base em conhecimento teórico sobre o fenômeno, resultados de estudos anteriores, inspeção gráfica dos dados ou procedimentos de busca em uma grade de valores.
Além disso, a função permite a atribuição de pesos às observações, resultando em um ajuste por mínimos quadrados não lineares ponderados. Nesse contexto, o algoritmo busca minimizar uma soma ponderada dos quadrados dos resíduos, minimizando a função $Q^*(\beta) = \sum_{i=1}^{n} w_i(y_i - \mu_i(\beta))^2$, em que w_i representa o peso associado à $i-$ésima observação. Dessa forma, observações com maiores pesos exercem maior influência no processo de estimação dos parâmetros.

4.2 Máxima verossimilhança

O método dos mínimos quadrados está diretamente relacionado à especificação de erros Gaussianos, independentes e com variância constante. Uma abordagem mais geral consiste em especificar uma distribuição de probabilidade para a variável resposta e obter os estimadores dos parâmetros por máxima verossimilhança.

No caso da distribuição Gaussiana para $Y|x$, a estimação por máxima verossimilhança consiste em encontrar os valores de θ e σ^2 que maximizam a função de log-verossimilhança, denotada por

$$\ell(\theta, \sigma^2) = -\frac{n}{2}log(2\pi) - \frac{n}{2}log(\sigma^2) - \frac{1}{2\sigma^2}\sum(y_i - \eta(x_i, \theta))^2 \tag{3}$$

Sob as suposições de normalidade, independência e variância constante, maximizar a função de log-verossimilhança em relação a θ é equivalente a minimizar a soma dos quadrados dos desvios, uma vez que ambos os procedimentos dependem da quantidade $\sum_{i=1}^{n}(y_i - \eta(x_i, \theta))^2$. Assim, os dois métodos não representam necessariamente modelos diferentes, mas correspondem a diferentes formas de formular a estimação sob determinadas suposições probabilísticas.

Em um contexto mais geral, portanto, a máxima verossimilhança permite incorporar explicitamente diferentes distribuições para a variável resposta e diferentes estruturas de variância.

Entretanto, maximizar Equação 3 envolve métodos numéricos iterativos, entre os quais se encontra o método de Newton-Raphson.

4.3 Valores iniciais

Como já mencionado, em geral não existe uma expressão analítica para obter $\hat{\theta}$. Por isso, a estimação é realizada numericamente e necessita de valores iniciais para os parâmetros. Esses valores iniciais não são as estimativas finais, apenas fornecem o ponto de partida para o procedimento numérico de estimação.

A escolha de valores iniciais pode utilizar informações obtidas do gráfico dos dados, da interpretação de parâmetros, da experiência do pesquisador e/ou à resultados de estudos anteriores.

> Dica
>
> Valores iniciais inadequados podem dificultar ou impedir a convergência do procedimento numérico. Por isso, a interpretação dos parâmetros e o conhecimento da escala das variáveis são importantes também na etapa de estimação. Por isso, recomenda-se prestar atenção na:
> **Escala das variáveis**
> Diferenças acentuadas entre as escalas das variáveis ou dos parâmetros podem dificultar a otimização numérica. Quando necessário, podem ser utilizadas estratégias como centralização, padronização ou reescala das unidades, desde que não comprometam a interpretação dos parâmetros.
> **Convergência**
> A convergência indica que o algoritmo encontrou uma solução numérica segundo o critério de parada adotado, mas **não garante a adequação do modelo**. Mesmo após a convergência, é necessário verificar a curva ajustada, os resíduos, a variabilidade dos erros e a plausibilidade da forma funcional adotada.
> **Convergência é uma propriedade do procedimento numérico; adequação é uma propriedade do modelo.**

4.4 Inferências sobre os parâmetros

Os métodos de estimação fornecem estimativas pontuais para os parâmetros do modelo, mas esses valores estão sujeitos à variabilidade amostral. A inferência procura quantificar essa incerteza e avaliar hipóteses sobre os parâmetros.

4.4.1 Testes de hipóteses sobre os parâmetros

Assim como na regressão linear, testes de hipóteses podem ser utilizados para avaliar afirmações específicas sobre os parâmetros de um modelo de regressão não linear. Nesse contexto, os procedimentos usuais de inferência fundamentam-se em aproximações para a distribuição dos estimadores.

Considerando um parâmetro θ_j, sob condições de regularidade e para amostras suficientemente informativas, utiliza-se a aproximação

$$\hat{\theta}_j \approx N\left(\theta_j, \text{Var}(\hat{\theta}_j)\right).$$

Para testar $H_0 : \theta_j = \theta_0$, utiliza-se a estatística

$$t = \frac{\hat{\theta}_j - \theta_0}{SE(\hat{\theta}_j)}.$$

Em modelos não lineares, essa estatística e seu erro-padrão são obtidos com base em uma aproximação linear local do modelo. Portanto, a inferência é aproximada e deve ser interpretada com cautela.

No contexto de mínimos quadrados não lineares, essa estatística é usualmente comparada a uma distribuição t de Student com $n - p$ graus de liberdade residuais.

No R, para um modelo ajustado pela função `nls()`, o comando

```
summary(modelo)
```

apresenta, para cada parâmetro, sua estimativa, erro-padrão, estatística t e p-valor.

> **Aviso**
>
> **Atenção à interpretação dos testes fornecidos pelo summary() do R** No R, o ajuste de modelo não linear pode ser feito pela função `nls()`, conforme visto nos exemplos do Capítulo 3. Já a função `summary()` apresenta, para cada parâmetro, sua estimativa, erro-padrão, estatística t e p-valor.
> Nessa saída, os valores de `p-valor` apresentados pelo `summary()` para cada parâmetro está associado ao teste
>
> $$H_0 : \theta_j = 0 \qquad \text{versus} \qquad H_1 : \theta_j \neq 0,$$
>
> de modo que a estatística apresentada corresponde a
>
> $$t = \frac{\hat{\theta}_j}{SE(\hat{\theta}_j)}.$$
>
> Entretanto, o valor zero nem sempre representa uma hipótese de interesse. Se o parâmetro corresponde, por exemplo, a uma assíntota, uma taxa de crescimento ou à localização de um ponto de inflexão, é necessário avaliar se $\theta_j = 0$ possui significado no contexto do fenômeno investigado.
> Portanto, antes de interpretar o p-valor fornecido pelo summary(), é necessário perguntar: "O valor zero corresponde, de fato, à hipótese que quero testar?"

Quando a hipótese de interesse envolve outro valor de referência, o teste deve ser formulado em relação a esse valor, e não automaticamente em relação a zero.

Cabe ressaltar que nos modelos não lineares a distribuição dos estimadores é obtida de forma aproximada. Assim, a utilização da distribuição t para a realização dos testes também constitui uma aproximação, cuja adequação tende a melhorar quando a linearização local do modelo representa satisfatoriamente seu comportamento em torno das estimativas.

i E o teste F global do modelo?

Na regressão linear, o teste F global é utilizado para avaliar conjuntamente se os coeficientes associados às variáveis explicativas são iguais a zero. Em modelos de regressão não linear, essa formulação não é diretamente transferível, pois atribuir simultaneamente o valor zero aos parâmetros pode não definir um modelo reduzido com significado estatístico ou científico. Testes baseados na estatística F podem ser utilizados para comparar modelos não lineares aninhados, quando um modelo reduzido pode ser obtido do modelo completo mediante restrições sobre seus parâmetros. Nesse caso, a comparação pode ser baseada na redução da soma de quadrados dos resíduos:

$$F = \frac{(SQR_R - SQR_C)/(p_C - p_R)}{SQR_C/(n - p_C)},$$

em que SQR_R e SQR_C representam as somas de quadrados dos resíduos dos modelos reduzido e completo, respectivamente, e p_R e p_C correspondem aos seus números de parâmetros. Em modelos não lineares a distribuição de referência desse teste é, em geral, aproximada. Assim, sua utilização requer que os modelos sejam efetivamente aninhados e que as restrições consideradas sejam compatíveis com a estrutura do modelo.

4.4.2 Intervalos de confiança para os parâmetros

Intervalo de confiança de Wald

A incerteza das estimativas dos parâmetros pode ser expressa por erros-padrão e intervalos de confiança. Em mínimos quadrados não lineares, a matriz de variâncias e covariâncias é aproximada localmente por

$$\widehat{\mathrm{Var}}(\hat{\theta}) = \hat{\sigma}^2 \left(\mathbf{J}^\top \mathbf{J}\right)^{-1}, \qquad \hat{\sigma}^2 = \frac{\mathrm{SQR}}{n - p},$$

em que $\mathbf{J}$ é a matriz Jacobiana avaliada em $\hat{\theta}$, SQR é a soma dos quadrados dos resíduos, n é o número de observações e p é o número de parâmetros. O erro-padrão de $\hat{\theta}_j$ é a raiz quadrada do elemento j da diagonal dessa matriz. Com base nessa aproximação, o intervalo de confiança de Wald para θ_j é

$$IC_{1-\alpha}(\theta_j) = \hat{\theta}_j \pm t_{1-\alpha/2,n-p}\, SE(\hat{\theta}_j).$$

Esse intervalo é simétrico em torno de $\hat{\theta}_j$ e usa a distribuição t com $(n-p)$ graus de liberdade, como é usual nos resultados de mínimos quadrados não lineares. Sua qualidade depende da adequação da aproximação linear local, pois se a função apresentar curvatura acentuada na região das estimativas, o intervalo pode representar mal a incerteza. Nesses casos, podem ser considerados métodos como o perfil de verossimilhança ou o bootstrap.

Intervalos de confiança baseados em perfil

No intervalo de Wald, calcula-se a margem de erro a partir do erro-padrão da estimativa. No intervalo baseado em perfil, avalia-se como o ajuste do modelo muda para diferentes valores de um parâmetro, reestimando os demais parâmetros a cada valor fixado. Esse procedimento é chamado de perfil do parâmetro.

A soma de quadrados perfilada para θ_j é

$$S_p(\theta_j) = \min_{\theta_{-j}} S(\theta_j, \theta_{-j}),$$

em que θ_{-j} reúne os demais parâmetros. A partir dessa função, calcula-se a estatística de perfil $\tau(\theta_j)$.

Para construir um intervalo bilateral de nível $1-\alpha$, encontram-se os valores de θ_j em que essa estatística atinge o valor crítico $c = t_{1-\alpha/2,\, n-p}$.

O limite inferior L_j é o valor de θ_j para o qual $\tau(\theta_j) = -c$, e o limite superior U_j é aquele para o qual $\tau(\theta_j) = c$:

$$\tau(L_j) = -t_{1-\alpha/2,\, n-p}, \qquad \tau(U_j) = t_{1-\alpha/2,\, n-p}.$$

Esses limites são encontrados numericamente ao percorrer o perfil do parâmetro. Como o perfil pode variar de forma diferente em cada lado da estimativa, o intervalo pode ser assimétrico em torno de $\hat{\theta}_j$.

Sob as hipóteses de erros independentes, normalmente distribuídos e com variância constante, o perfil da soma de quadrados residual corresponde ao perfil da verossimilhança. Assim, o perfil da soma de quadrados residual corresponde, sob essas hipóteses, como um perfil de verossimilhança. No R, os intervalos de perfil para objetos nls são calculados a partir do perfil da soma de quadrados residual.

Intervalos de confiança no R

Para um modelo ajustado pela função `nls()`, o R permite obter os dois tipos de intervalos apresentados anteriormente:

```
# Intervalos de confiança baseados em perfil
confint(modelo)

# Intervalos de confiança de Wald
confint.default(modelo)
```

Ambos os métodos quantificam a incerteza das estimativas, mas usam procedimentos distintos. Essa diferença pode ser relevante quando a aproximação local utilizada pelo intervalo de Wald não descreve bem o comportamento do modelo.
Para aprofundar o estudo da inferência em modelos de regressão não linear no R, recomenda-se consultar também o tutorial do pacote **nlstools**, *A Toolbox for Nonlinear Regression in R: The Package nlstools*, que apresenta ferramentas específicas para ajuste, diagnóstico e construção de intervalos de confiança em modelos não lineares.

5 Diagnóstico do modelo

Depois de estimar os parâmetros, é necessário verificar se o modelo ajustado representa adequadamente os dados e se as suposições utilizadas na inferência são razoáveis.

Os valores ajustados são dados por

$$\widehat{Y}_i = f(\mathbf{x}_i, \hat{\theta}),$$

e os resíduos são

$$e_i = Y_i - \widehat{Y}_i.$$

Os procedimentos utilizados para a análise dos resíduos são bastante semelhantes aos aplicados para os modelos de regressão linear. Nesta seção, esses procedimentos serão retomados no contexto dos modelos não lineares.

5.1 Exemplo: velocidade de uma reação enzimática

Para ilustrar os procedimentos de diagnóstico e avaliação do ajuste, será utilizado o conjunto de dados `Puromycin`, disponível no pacote datasets do R. O conjunto de dados contém 23 observações da velocidade de uma reação enzimática em diferentes concentrações de substrato, considerando células tratadas e não tratadas com puromicina.

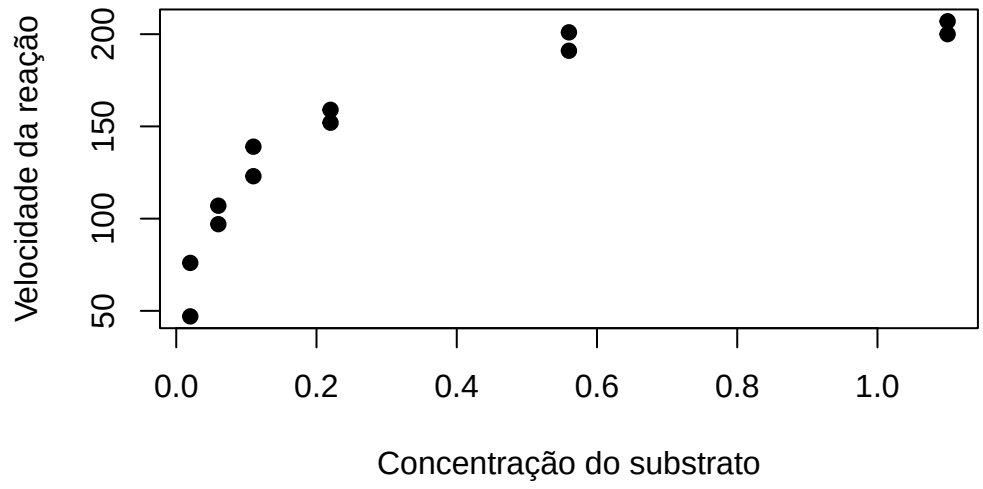
Inicialmente, serão utilizadas apenas as observações referentes ao grupo tratado:

```
da_tratado <- subset(Puromycin, state == "treated")
da_tratado
```

```
   conc rate   state
1  0.02   76 treated
2  0.02   47 treated
3  0.06   97 treated
4  0.06  107 treated
5  0.11  123 treated
6  0.11  139 treated
7  0.22  159 treated
8  0.22  152 treated
9  0.56  191 treated
10 0.56  201 treated
11 1.10  207 treated
12 1.10  200 treated
```

O diagrama de dispersão permite observar a relação entre a concentração do substrato e a velocidade da reação:

```
plot(rate ~ conc,
     data = da_tratado,
     pch = 19,
     xlab = "Concentração do substrato",
     ylab = "Velocidade da reação")
```



Observa-se um crescimento da resposta seguido de uma tendência à estabilização, comportamento compatível com funções de saturação.

5.1.1 Modelo de Michaelis–Menten

O primeiro modelo considerado será o de Michaelis–Menten,

$$Y_i = \frac{V_{\max} x_i}{K_m + x_i} + \epsilon_i,$$

em que $V_{\max}$ representa a velocidade máxima da reação, a assíntota do modelo, e K_m corresponde à concentração de substrato na qual a velocidade atinge metade de $V_{\max}$.

O modelo pode ser ajustado por:

```
mod_mm<- nls(
  rate ~ alpha * conc / (beta + conc),
  data = da_tratado,
  start = list(alpha = 200, beta = 0.05)
)
summary(mod_mm)
```

```
Formula: rate ~ alpha * conc/(beta + conc)

Parameters:
       Estimate Std. Error t value Pr(>|t|)
alpha 2.127e+02  6.947e+00  30.615 3.24e-11 ***
beta  6.412e-02  8.281e-03   7.743 1.57e-05 ***
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 10.93 on 10 degrees of freedom

Number of iterations to convergence: 5
Achieved convergence tolerance: 8.768e-06
```

Para esses dados, são obtidas aproximadamente as estimativas

$$\hat{\alpha} = 212{,}68 \qquad \text{e} \qquad \hat{\beta} = 0{,}064.$$

Avaliação gráfica do ajuste

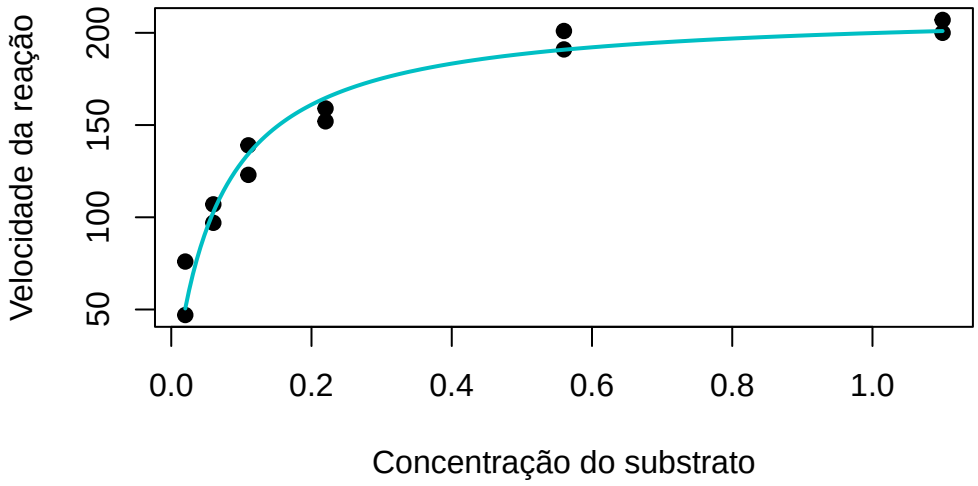
Uma primeira avaliação consiste em representar conjuntamente os valores observados e a curva estimada:

```r
x_grid_puro <- seq(min(da_tratado$conc),
                   max(da_tratado$conc),
                   length.out = 200)

y_mm <- predict(
  mod_mm,
  newdata = data.frame(conc = x_grid_puro)
)

plot(rate ~ conc,
     data = da_tratado,
     pch = 19,
     xlab = "Concentração do substrato",
     ylab = "Velocidade da reação")

lines(x_grid_puro, y_mm, col="#00BFC4", lwd = 2)
```



A representação gráfica permite verificar se o formato imposto pelo modelo é coerente com o comportamento observado nos dados. No modelo de Michaelis–Menten, espera-se crescimento progressivamente mais lento da resposta à medida que esta se aproxima da assíntota.

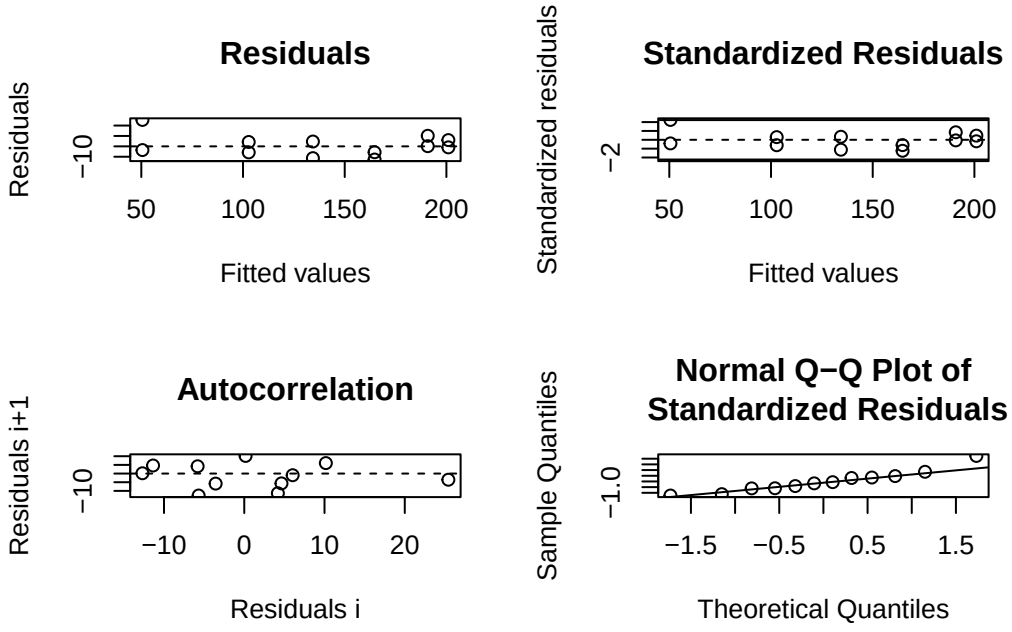
5.2 Análise dos resíduos

Após ajustar o modelo, a análise dos resíduos ajuda a avaliar se a forma funcional e as pressuposições adotadas são compatíveis com os dados. Para isso, examinaremos possíveis padrões nos resíduos, alterações na dispersão, desvios da normalidade e dependência entre observações.

O pacote nlstools fornece gráficos de diagnóstico para objetos ajustados com `nls()`

```
library(nlstools)

# Análise dos resíduos em um MNL
res_puro<- nlsResiduals(mod_mm)
plot(res_puro)
```




```
# Valores ajustados pelo modelo
aj_puro_mm  <- fitted(mod_mm)
```

Por padrão, são apresentados quatro gráficos que auxiliam na avaliação visual dos resíduos:

- **Resíduos versus valores ajustados**: ajuda a avaliar se os resíduos se distribuem em torno de zero sem padrões sistemáticos. Curvaturas ou tendências podem indicar falta de ajuste do modelo.

- **Resíduos padronizados versus valores ajustados**: permite examinar possíveis mudanças na dispersão dos resíduos ao longo dos valores ajustados e identificar observações com valores padronizados extremos, o que pode indicar variância não constante.
- **Autocorrelação**: ajuda a identificar possível dependência entre observações consecutivas, especialmente quando sua ordem tem significado.
- **Gráfico Q–Q Plot**: permite avaliar visualmente se a distribuição dos resíduos é compatível com a normalidade. Desvios sistemáticos em relação à reta podem indicar afastamento da normalidade

> **i** Observação
>
> Os gráficos padrão de `nlstools()` não avaliam distância de Cook nem alavancagem. O pacote oferece também outros gráficos, como resíduos padronizados versus ajustados e raiz do valor absoluto dos resíduos padronizados versus ajustados.

Embora o modelo ajustado seja não linear, esses diagnósticos se baseiam em uma aproximação linear local do modelo, construída a partir da Jacobiana avaliada nas estimativas dos parâmetros. Por isso, os resultados devem ser interpretados como diagnósticos aproximados.

5.3 Testes estatísticos

A inspeção gráfica dos resíduos pode ser complementada pelos testes formais, como:

- Shapiro–Wilk, para investigar a compatibilidade dos resíduos com a normalidade;
- Breusch–Pagan, para investigar a homocedasticidade;
- Durbin–Watson, para investigar autocorrelação de primeira ordem.

Novamente, como em modelos de regressão não linear, a aplicação desses testes pode ser fundamentada em aproximações linear local do modelol, potanto, os resultados devem ser interpretados levando em conta essa aproximação.

Quando forem identificadas evidências de autocorrelação, uma alternativa consiste em manter a função média do modelo e incorporar uma estrutura de correlação aos erros, como um processo autorregressivo de primeira ordem, AR(1).

> **Em síntese**
>
> A avaliação das pressuposições deve considerar conjuntamente os gráficos e os resultados dos testes estatísticos. A presença de desvios relevantes pode indicar a necessidade de reconsiderar a forma funcional; mudanças na dispersão podem sugerir variância não constante; e padrões entre resíduos consecutivos podem apontar dependência. Esses aspectos devem ser examinados antes de interpretar a inferência ou comparar modelos.

```r
# Resíduos numéricos do modelo não linear
e <- residuals(mod_mm)

# 1. Shapiro-Wilk: normalidade dos resíduos
teste_sw <- shapiro.test(e)
teste_sw
```

```
    Shapiro-Wilk normality test

data:  e
W = 0.92902, p-value = 0.3698
```

Para os testes de Breusch–Pagan e Durbin–Watson, usamos uma regressão auxiliar baseada na aproximação linear local do modelo, construída com a Jacobiana:

```r
# Jacobiana avaliada nas estimativas do modelo
J <- mod_mm$m$gradient()

# Resposta da aproximação linear local
y_estrela <- e + drop(J %*% coef(mod_mm))

# Regressão auxiliar local
dados_aux <- as.data.frame(J)
dados_aux$y_estrela <- y_estrela

reg_local <- lm(y_estrela ~ . - 1, data = dados_aux)

# 2. Breusch-Pagan: homocedasticidade
library(lmtest)

teste_bp <- bptest(reg_local)
teste_bp
```

```
    studentized Breusch-Pagan test

data:  reg_local
BP = 1.1461, df = 1, p-value = 0.2844
```

```r
# 3. Durbin-Watson: autocorrelação de primeira ordem
teste_dw <- dwtest(reg_local, alternative = "two.sided")
teste_dw
```

```
    Durbin-Watson test

data:  reg_local
DW = 1.615, p-value = 0.2844
alternative hypothesis: true autocorrelation is not 0
```

```r
# Tabela de resultados dos testes aplicados:
resultados_testes <- data.frame(
  Teste = c("Shapiro-Wilk", "Breusch-Pagan", "Durbin-Watson"),
  Estatística = c(
    unname(teste_sw$statistic),
    unname(teste_bp$statistic),
    unname(teste_dw$statistic)
  ),
  p_valor = c(
    teste_sw$p.value,
    teste_bp$p.value,
    teste_dw$p.value
  )
)

knitr::kable(
  resultados_testes,
  digits = 4,
  caption = "Testes de diagnóstico dos resíduos do modelo de Michaelis-Menten"
)
```

Tabela 3: Testes de diagnóstico dos resíduos do modelo de Michaelis–Menten

Teste	Estatística	p_valor
Shapiro-Wilk	0.9290	0.3698
Breusch-Pagan	1.1461	0.2844
Durbin-Watson	1.6150	0.2844

6 Qualidade do ajuste e comparação entre modelos

Diferentes funções não lineares podem representar de forma plausível um mesmo fenômeno. Para avaliar a qualidade dos ajustes e orientar a seleção do modelo mais adequado, comparamos diferentes medidas de adequabilidade.

Para ilustrar essa comparação, além do modelo de Michaelis–Menten será considerado um **modelo de saturação exponencial**, dado por

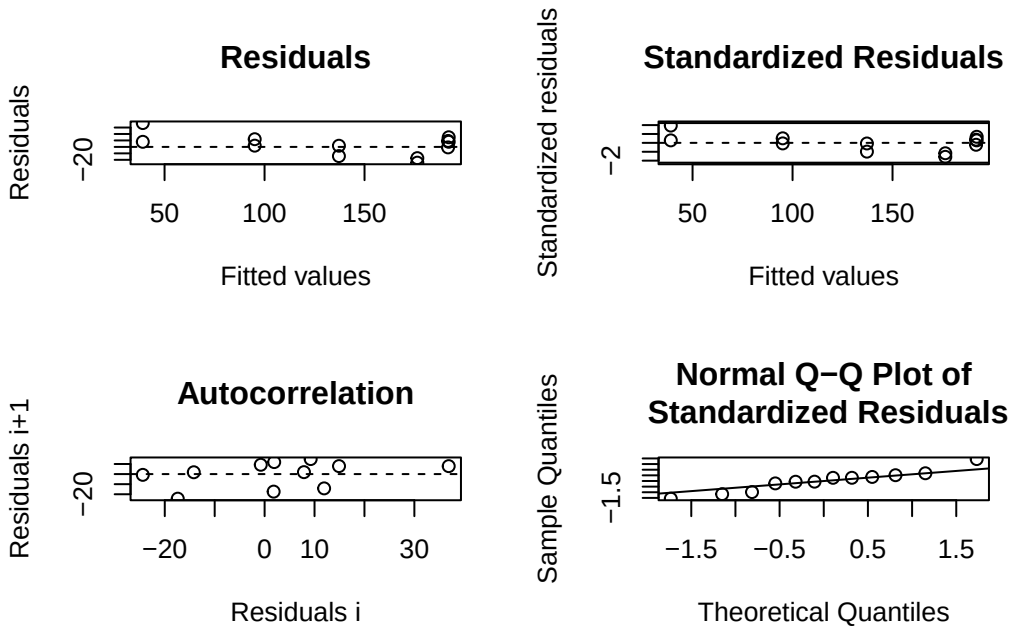
$$Y_i = \alpha\,(1 - e^{-\kappa x_i}) + \epsilon_i,$$

em que α representa a assíntota superior e $\kappa > 0$ controla a velocidade com que a resposta se aproxima dessa assíntota.

O modelo pode ser ajustado por:

```
# Ajuste do modelo de saturação exponencial
mod_exp <- nls(
  rate ~ alpha * (1 - exp(-kappa * conc)),
  data = da_tratado,
  start = list(alpha = 200, kappa = 10)
)
```

> **i** Diagnóstico gráfico e testes dos resíduos
>
> Os gráficos ajudam a identificar padrões nos resíduos, mudanças na dispersão, possíveis desvios da normalidade e dependência entre observações consecutivas. Os testes complementam a avaliação visual; seus resultados não devem ser interpretados isoladamente.
>
> ```
> # Gráficos de diagnóstico
> res_mm <- nlsResiduals(mod_exp)
> plot(res_mm)
> ```


Residuals
Residuals
−20
50
100
150
Fitted values
Standardized Residuals
Standardized residuals
−2
50
100
150
Fitted values
Autocorrelation
Residuals i+1
−20
−20
0
10
30
Residuals i
Normal Q−Q Plot of
Standardized Residuals
Sample Quantiles
−1.5
−1.5
−0.5
0.5
1.5
Theoretical Quantiles

```r
# Testes: Shapiro-Wilk aos resíduos; Breusch-Pagan e Durbin-Watson,
# com base na aproximação linear local pela Jacobiana
testes_nls <- function(modelo) {
  residuos <- residuals(modelo)
# Normalidade dos resíduos
  sw <- shapiro.test(residuos)
# Regressão auxiliar baseada na aproximação linear local
  J <- modelo$m$gradient()
  y_estrela <- residuos + drop(J %*% coef(modelo))
  dados_aux <- as.data.frame(J)
  dados_aux$y_estrela <- y_estrela
  reg_local <- lm(y_estrela ~ . - 1, data = dados_aux)
# Variância constante e autocorrelação de primeira ordem
  bp <- bptest(reg_local)
  dw <- dwtest(reg_local, alternative = "two.sided")
  data.frame(
    Teste = c("Shapiro-Wilk", "Breusch-Pagan", "Durbin-Watson"),
    Estatistica = c(
      unname(sw$statistic),
      unname(bp$statistic),
      unname(dw$statistic)
    ),
    p_valor = c(sw$p.value, bp$p.value, dw$p.value)
  )
}

#testes_mm <- testes_nls(mod_mm)
#testes_mm
testes_exp <- testes_nls(mod_exp)
testes_exp
```

```
          Teste Estatistica    p_valor
1  Shapiro-Wilk   0.9479527 0.60727402
2 Breusch-Pagan   0.4153510 0.51926598
3 Durbin-Watson   1.0100544 0.02112726
```

A interpretação do teste de Durbin–Watson depende da ordem das observações. Como os dados de concentração não têm uma ordem temporal natural, o teste deve ser entendido em relação à ordenação usada na base.

O gráfico apresentado na Figura 5 permite comparar visualmente os dois ajustes:

```r
y_exp <- predict(
  mod_exp,
  newdata = data.frame(conc = x_grid_puro)
)

curvas <- data.frame(
  conc = rep(x_grid_puro, 2),
  rate = c(y_mm, y_exp),
  Modelo = rep(c("Michaelis-Menten", "Exponencial simples"),
               each = length(x_grid_puro))
)

library(ggplot2)
#| out-width: "80%"
ggplot(da_tratado, aes(conc, rate)) +
  geom_point(color = "gray40") +
  geom_line(
    data = curvas,
    aes(color = Modelo, linetype = Modelo),
    linewidth = 1
  ) +
  labs(
    x = "Concentração do substrato",
    y = "Velocidade da reação",
    color = "Modelo",
    linetype = "Modelo"
  ) +
  theme_minimal() +
   theme(
    legend.position = c(0.85, 0.45),
    legend.justification = c(1, 1),
    legend.background = element_rect(fill = alpha("white", 0.6))
  )
```

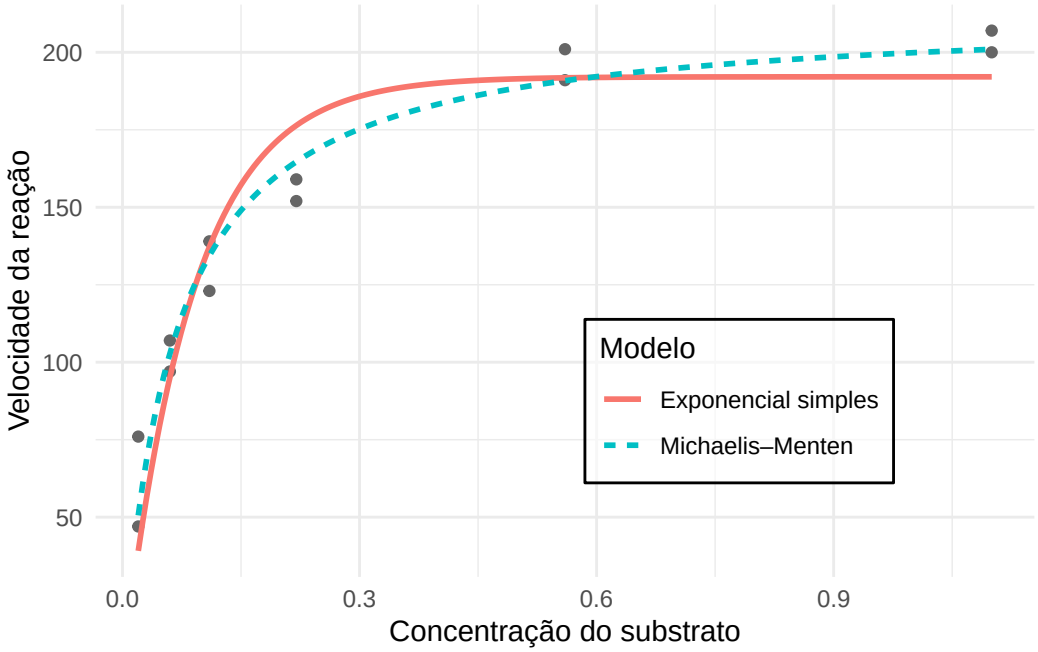


Figura 5: Modelo de Michaelis–Menten e Exponencial Simples ajustados às observações referentes ao grupo tratado.

6.1 Medidas de adequabilidade do ajuste

Considere n observações e q parâmetros estimados na função média.

- A soma de quadrados dos resíduos (SQR) é

$$\text{SQR} = \sum_{i=1}^{n} (y_i - \hat{y}_i)^2,$$

em que y_i e $\hat{y}_i$ são, respectivamente, o valor observado e o valor ajustado. Para modelos ajustados aos mesmos dados e à mesma resposta, valores menores de SQR indicam menor discrepância residual.

- O desvio-padrão residual (DPR) considera os graus de liberdade residuais:

$$\text{DPR} = \sqrt{\frac{\text{SQR}}{n-q}}.$$

Valores menores indicam menor dispersão residual, levando em conta o número de parâmetros estimados.

- O coeficiente de determinação ajustado é

$$R^2_{\text{aj.}} = 1 - \frac{\text{SQR}\,/(n-q)}{\text{SQT}\,/(n-1)} = 1 - \frac{n-1}{n-q}(1-R^2),$$

em que $\text{SQT} = \sum_{i=1}^{n}(y_i - \bar{y})^2$, $R^2 = 1 - \frac{\text{SQR}}{\text{SQT}}$ e q é o número total de parâmetros estimados na função média.

Em regressão não linear, valores de R^2 ou $R^2_{aj.}$ só fazem sentido para comparação de modelos; como número isolado não quer dizer muita coisa em termos de desempenho do modelo até mesmo porque estes coeficientes medem o grau de associação linear entre as observações e suas respectivas respostas ajustadas. Por isso, a principal validade dessas métricas reside na comparação relativa entre modelos concorrentes ajustados aos mesmos dados.

- Sob erros independentes, normalmente distribuídos e com variância constante, os critérios de informação AIC e BIC podem ser calculados a partir da log-verossimilhança:

$$\text{AIC} = -2\ell(\hat{\theta}, \hat{\sigma}^2) + 2K, \quad \text{BIC} = -2\ell(\hat{\theta}, \hat{\sigma}^2) + K\log(n),$$

em que ℓ é a log-verossimilhança e $K = q + 1$ conta os q parâmetros da função média e o parâmetro de variância σ^2. Em geral, valores menores de AIC e BIC indicam melhor equilíbrio entre ajuste e complexidade, na comparação de modelos ajustados aos mesmos dados.

- O PRESS avalia o desempenho preditivo por validação leave-one-out. Seja $\hat{y}_{i(-i)}$ a previsão para a observação i, obtida após ajustar o modelo sem essa observação. Então,

$$\text{PRESS} = \sum_{i=1}^{n} \left(y_i - \hat{y}_{i(-i)}\right)^2.$$

Valores menores de PRESS indicam menor erro preditivo nesse procedimento. Nos modelos não lineares, cada previsão leave-one-out requer reajustar o modelo às $n-1$ observações restantes.

$\Rightarrow$ Na comparação entre os modelos, menores valores de **SQR** e **DPR** indicam menor discrepância entre os valores observados e ajustados. Menores valores de **AIC** e **BIC** indicam melhor compromisso entre qualidade do ajuste e complexidade. O **PRESS** avalia o desempenho preditivo: menores valores indicam menor erro de predição quando cada observação é, sucessivamente, deixada fora do ajuste. Já o R^2 apresentado deve ser utilizado como uma medida descritiva da *redução relativa* da soma de quadrados dos resíduos em relação ao uso da média da resposta.

Contudo, a escolha do modelo não deve ser baseada em uma única medida. É necessário considerar conjuntamente a qualidade numérica do ajuste, o diagnóstico dos resíduos, a interpretação dos parâmetros e a plausibilidade da forma funcional para o fenômeno estudado.

Calculando essas medidas para os dois modelos ajustados, temos:

```r
#Cálculo da medida PRESS
press_nls <- function(modelo, dados, resposta) {
  formula_modelo <- formula(modelo)
  inicio <- as.list(coef(modelo))
  erros2 <- numeric(nrow(dados))

  for (i in seq_len(nrow(dados))) {
    ajuste_i <- try(
      nls(
        formula_modelo,
        data = dados[-i, , drop = FALSE],
        start = inicio,
        control = nls.control(maxiter = 200, warnOnly = TRUE)
      ),
      silent = TRUE
    )

    if (inherits(ajuste_i, "try-error")) {
      return(NA_real_)
    }

    predicao <- predict(ajuste_i, newdata = dados[i, , drop = FALSE])
    erros2[i] <- (dados[[resposta]][i] - predicao)^2
  }

  sum(erros2)
}

# Função para calcular as medidas de ajuste
medidas_ajuste <- function(modelo, dados, resposta) {
  y <- dados[[resposta]]
  n <- length(y)
  p <- length(coef(modelo))
  sqr <- deviance(modelo)
  sqt <- sum((y - mean(y))^2)

  data.frame(
    SQR = sqr,
    DPR = sqrt(sqr / (n - p)),
    R2_aj. = 1 - (sqr / (n - p)) / (sqt / (n - 1)),
    AIC = AIC(modelo),
    BIC = BIC(modelo),
```

```
    PRESS = press_nls(modelo, dados, resposta)
  )
}

comparacao <- rbind(
  "Michaelis-Menten" = medidas_ajuste(mod_mm, da_tratado, "rate"),
  "Exponencial simples" = medidas_ajuste(mod_exp, da_tratado, "rate")
)

# Montando tabela com os resultados
#| label: tbl-adequabilidade

knitr::kable(
  round(comparacao, 3),
  caption = "Medidas de adequabilidade dos modelos de saturação."
)
```

Tabela 4: Medidas de adequabilidade dos modelos de saturação.

	SQR	DPR	R2_aj.	AIC	BIC	PRESS
Michaelis–Menten	1195.449	10.934	0.957	95.271	96.726	1614.846
Exponencial simples	3041.553	17.440	0.892	106.477	107.932	4057.837

Para os dados analisados, o modelo de Michaelis–Menten apresenta menor SQR e menor desvio-padrão residual, maior R^2, menores valores de AIC, BIC e PRESS. Portanto, segundo todas as medidas consideradas, esse modelo apresenta melhor qualidade de ajuste aos dados do grupo tratado.

7 Comparação de modelos não lineares aninhados

Dois modelos são considerados aninhados quando um deles, denominado modelo reduzido, pode ser obtido a partir de outro, o modelo completo, mediante a imposição de uma ou mais restrições sobre seus parâmetros. Nesse contexto, além das medidas de ajuste, é possível avaliar se a inclusão de parâmetros adicionais proporciona uma redução estatisticamente significativa na soma de quadrados dos resíduos (SQR).

A comparação entre modelos aninhados é formalizada pelo teste F, que avalia as hipóteses:

H_0 : todas as restrições sobre os parâmetros impostas pelo modelo reduzido são válidas.
H_a : pelo menos uma das restrições sobre os parâmetros impostas pelo modelo reduzido é inválida.

Considerando dois modelos ajustados ao mesmo conjunto de observações, com q_R e q_C parâmetros, respectivamente, em que $q_R < q_C$, a estatística do *teste* F é dada por:

$$F = \frac{(SQR_R - SQR_C)/(q_C - q_R)}{SQR_C/(n - q_C)},$$

em que SQR_R e SQR_C representam as somas de quadrados dos resíduos dos modelos reduzido e completo, respectivamente, e n corresponde ao número de observações.

Sob as suposições de erros independentes, Gaussianos e com variância constante, e satisfeitas as condições de regularidade, a estatística pode ser comparada aproximadamente à distribuição F com $(q_C - q_R)$ e $(n - q_C)$ graus de liberdade.

7.1 Exemplo: comparação de curvas de Michaelis–Menten

Para ilustrar essa situação, serão utilizados agora os dois grupos presentes nos dados `Puromycin`: `treated` e `untreated`.

O objetivo é avaliar se os dois grupos experimentais, definidos pela presença ou ausência de tratamento com puromicina, podem ser descritos por uma única curva que relaciona a concentração de substrato à velocidade da reação ou se cada grupo requer parâmetros próprios.

Modelo completo: quatro parâmetros

No modelo completo (M_C), os parâmetros podem assumir valores distintos nos dois grupos:

$$\mu_U(x) = \frac{\alpha_U x}{\beta_U + x}, \quad \text{e} \quad \mu_T(x) \quad = \frac{\alpha_T x}{\beta_T + x},$$

em que U indica o grupo não tratado e T o tratado. Definindo

$$z_i = \begin{cases} 0, & \text{não tratado,} \\ 1, & \text{tratado} \end{cases}, \quad \Delta_\alpha = \alpha_T - \alpha_U \quad \text{e} \quad \Delta_\beta = \beta_T - \beta_U,$$

a função média do modelo completo pode ser escrita como

$$E(Y_i \mid x_i, z_i) = \frac{(\alpha_U + \Delta_\alpha z_i)x_i}{\beta_U + \Delta_\beta z_i + x_i}.$$

Assim, M_C possui quatro parâmetros: α_U, Δ_α, β_U e Δ_β.

```r
# Carregando a base de dados
data("Puromycin", package = "datasets")
dados <- Puromycin
dados$z <- as.numeric(dados$state == "treated")

# Ajustando o modelo completo
mod_C <- nls(
  rate ~ (alpha_U + delta_alpha * z) * conc /
    (beta_U + delta_beta * z + conc),
  data = dados,
  start = list(
    alpha_U = 160, delta_alpha = 50,
    beta_U = 0.05, delta_beta = 0.01
  )
)
summary(mod_C)
```

```
Formula: rate ~ (alpha_U + delta_alpha * z) * conc/(beta_U + delta_beta *
    z + conc)

Parameters:
             Estimate Std. Error t value Pr(>|t|)
alpha_U     1.603e+02  6.896e+00  23.242 2.04e-15 ***
delta_alpha 5.240e+01  9.551e+00   5.487 2.71e-05 ***
beta_U      4.771e-02  8.281e-03   5.761 1.50e-05 ***
delta_beta  1.641e-02  1.143e-02   1.436    0.167
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 10.4 on 19 degrees of freedom

Number of iterations to convergence: 5
Achieved convergence tolerance: 3.163e-06
```

As estimativas dos parâmetros do grupo tratado são obtidas pelas relações

$$\hat{\alpha}_T = \hat{\alpha}_U + \widehat{\Delta}_\alpha \quad \text{e} \quad \hat{\beta}_T = \hat{\beta}_U + \widehat{\Delta}_\beta.$$

Modelo reduzido 1: dois parâmetros e uma única curva

O primeiro modelo reduzido (M_{R1}) considera que ambos os grupos compartilham a mesma velocidade máxima e a mesma constante de Michaelis–Menten. Isso corresponde às restrições:

$$H_0: \quad \Delta_\alpha = 0 \quad \text{e} \quad \Delta_\beta = 0.$$

```
# Ajustando o M_{R1}
mod_R1 <- nls(
  rate ~ alpha * conc / (beta + conc),
  data = dados,
  start = list(alpha = 190, beta = 0.06)
)
summary(mod_R1)
```

```
Formula: rate ~ alpha * conc/(beta + conc)

Parameters:
       Estimate Std. Error t value Pr(>|t|)
alpha 190.80634    8.76459  21.770 6.84e-16 ***
beta    0.06039    0.01077   5.608 1.45e-05 ***
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 18.61 on 21 degrees of freedom

Number of iterations to convergence: 4
Achieved convergence tolerance: 2.255e-06
```

```
# Teste F - modelos aninhados: M_{R1} e M_C
comparacao_1 <- anova(mod_R1, mod_C)
comparacao_1
```

```
Analysis of Variance Table

Model 1: rate ~ alpha * conc/(beta + conc)
Model 2: rate ~ (alpha_U + delta_alpha * z) * conc/(beta_U + delta_beta * z + conc)
  Res.Df Res.Sum Sq Df Sum Sq F value    Pr(>F)
1     21     7276.5
2     19     2055.1  2 5221.5  24.138 6.075e-06 ***
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
```

As SQR são aproximadamente $SQR_{R1} = 7276{,}55$ e $SQR_C = 2055{,}05$. Com $n = 23$, obtém-se

$$F = \frac{(7276{,}55 - 2055{,}05)/(4-2)}{2055{,}05/(23-4)} \approx 24{,}14.$$

O valor-p é inferior a 0,001. Ao nível de significância de 5%, há indicação de rejeição de H_0. Assim, incorporar parâmetros específicos por grupo ao ajuste proporcionará uma redução significativa da SQR. Portanto, **uma única curva de Michaelis–Menten não parece adequada para representar ambos os grupos**. A comparação, contudo, não identifica qual parâmetro difere entre eles.

Modelo reduzido 2: três parâmetros e β comum

Considera-se, então, um segundo modelo reduzido (M_{R2}), no qual as velocidades máximas podem diferir, mas o parâmetro β é compartilhado pelos grupos. Com isso, temos a função média:

$$E(Y_i \mid x_i, z_i) = \frac{(\alpha_U + \Delta_\alpha z_i)x_i}{\beta + x_i}.$$

Essa função é obtida a partir do modelo completo pela restrição $H_0 : \quad \Delta_\beta = 0$, ou, equivalentemente, $\beta_T = \beta_U$.

```
# Ajustando M_{R2}:
mod_R2 <- nls(
  rate ~ (alpha_U + delta_alpha * z) * conc /
    (beta + conc),
  data = dados,
  start = list(
    alpha_U = 160, delta_alpha = 50,
    beta = 0.055
  )
)
summary(mod_R2)
```

```
Formula: rate ~ (alpha_U + delta_alpha * z) * conc/(beta + conc)

Parameters:
             Estimate Std. Error t value Pr(>|t|)
alpha_U     166.60407    5.80743  28.688  < 2e-16 ***
delta_alpha  42.02596    6.27214   6.700 1.61e-06 ***
beta          0.05797    0.00591   9.809 4.37e-09 ***
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
```

```
Residual standard error: 10.59 on 20 degrees of freedom

Number of iterations to convergence: 5
Achieved convergence tolerance: 1.579e-06
```

```r
# Teste F - modelos aninhados M_{R2} e M_C
comparacao_2 <- anova(mod_R2, mod_C)
comparacao_2
```

```
Analysis of Variance Table

Model 1: rate ~ (alpha_U + delta_alpha * z) * conc/(beta + conc)
Model 2: rate ~ (alpha_U + delta_alpha * z) * conc/(beta_U + delta_beta * z + conc)
  Res.Df Res.Sum Sq Df Sum Sq F value Pr(>F)
1     20     2240.9
2     19     2055.1  1 185.84  1.7182 0.2056
```

As SQR são aproximadamente $SQR_{R2} = 2240{,}89$ e $SQR_C = 2055{,}05$. Assim,

$$F = \frac{(2240{,}89 - 2055{,}05)/(4-3)}{2055{,}05/(23-4)} \approx 1{,}72.$$

O valor-p é aproximadamente 0,206. Ao nível de significância de 5%, não há evidências para rejeição de H_0. Portanto, **não foram encontradas evidências suficientes de que o parâmetro β difira entre os grupos**. A ausência de rejeição não implica igualdade entre os parâmetros, mas indica que permitir essa diferença não produz melhora estatisticamente significativa no ajuste. Ressalta-se, contudo, que o modelo já admite que as velocidades máximas possam variar entre os grupos.

7.1.1 Síntese da comparação dos três modelos

A Tabela 6 resume os resultados que mostram a inadequação de uma única curva de Michaelis–Menten para descrever ambos os grupos.

Tabela 5: Resultados dos testes-F aplicados aos modelos aninhados.

Modelos comparados	Restrições sob H_0	Valor F	Valor-p
M_{R1} vs. M_C	$\Delta_\alpha = 0$ e $\Delta_\beta = 0$	24,14	$< 0{,}001$
M_{R2} vs. M_C	$\Delta_\beta = 0$	1,72	0,206

Quando se permitem velocidades máximas distintas, a inclusão de um parâmetro adicional para diferenciar β não produziu redução estatisticamente significativa da SQR. Entre os modelos considerados, M_{R2} é a alternativa mais parcimoniosa compatível com essas comparações, sem dispensar a análise dos resíduos e a verificação das suposições adotadas para os erros.

A Figura 6 apresenta as observações de cada grupo e as curvas estimadas. As cores distinguem os tratamentos, enquanto os tipos de linha identificam os modelos. O modelo reduzido 1 possui uma única curva, comum aos dois grupos; os outros modelos apresentam duas curvas cada.

```r
cores <- c(treated = "#2166AC", untreated = "#D6604D")

plot(
  rate ~ conc, data = dados,
  col = cores[as.character(dados$state)],
  pch = ifelse(dados$z == 1, 16, 17),
  xlab = "Concentração de substrato (ppm)",
  ylab = "Velocidade da reação (contagens/min/min)",
  las = 1,
  ylim = c(0, max(dados$rate) * 1.12)
)

conc_seq <- seq(0, max(dados$conc), length.out = 200)

# Reduzido 1: curva única, cinza pontilhada
lines(
  conc_seq,
  predict(mod_R1, newdata = data.frame(conc = conc_seq)),
  col = "gray35", lty = 3, lwd = 2.5
)

for (grupo in c("treated", "untreated")) {
  novos <- data.frame(
    conc = conc_seq,
    z = as.numeric(grupo == "treated")
  )

  # Completo: linha contínua
  lines(
    conc_seq, predict(mod_C, newdata = novos),
    col = cores[grupo], lty = 1, lwd = 2
  )

  # Reduzido 2: linha tracejada
```

```
  lines(
    conc_seq, predict(mod_R2, newdata = novos),
    col = cores[grupo], lty = 2, lwd = 2
  )
}

legend(
  "bottomright",
  legend = c(
    "Tratado: observações",
    "Não tratado: observações",
    "Completo (4 parâmetros) - tratado",
    "Completo (4 parâmetros) - não tratado",
    "Reduzido 2 (3 parâmetros) - tratado",
    "Reduzido 2 (3 parâmetros) - não tratado",
    "Reduzido 1 (2 parâmetros)"
  ),
  col = c(
    cores["treated"], cores["untreated"],
    cores["treated"], cores["untreated"],
    cores["treated"], cores["untreated"],
    "gray35"
  ),
  pch = c(16, 17, NA, NA, NA, NA, NA),
  lty = c(NA, NA, 1, 1, 2, 2, 3),
  lwd = c(NA, NA, 2, 2, 2, 2, 2.5),
  bty = "n", cex = 0.82
)
```

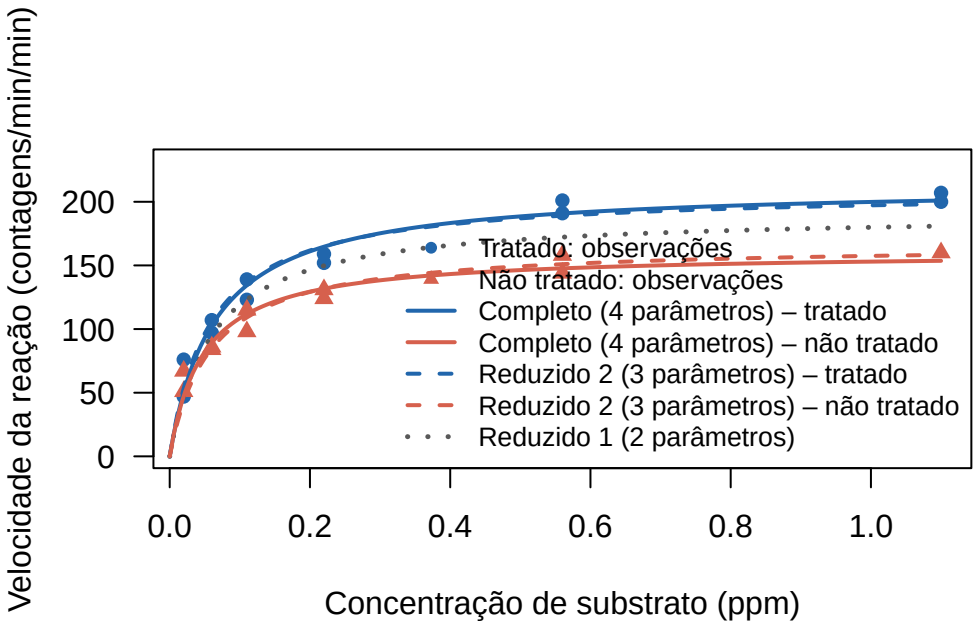


Figura 6: Dados Puromycin e curvas de Michaelis–Menten ajustadas pelos modelos completo e reduzidos.

i Interpretação do teste F

O teste F compara a redução na soma de quadrados dos resíduos obtida ao liberar parâmetros adicionais com a variabilidade residual do modelo completo. A rejeição de H_0 indica que as restrições impostas pelo modelo reduzido não são compatíveis com os dados. A não rejeição, por outro lado, significa apenas que a evidência disponível não justifica a complexidade adicional, sem implicar equivalência entre os modelos.
Em regressão não linear, o teste F é aproximado e depende das condições de regularidade e das suposições sobre os erros (independência, normalidade e homogeneidade da variância). Por isso, a análise de diagnóstico dos resíduos continua essencial para validar a comparação.

Teste de falta de ajuste em observações repetidas

Quando existem **observações repetidas nos mesmos níveis da variável explicativa**, também é possível investigar a falta de ajuste da função não linear. Para isso, o modelo ajustado pode ser **comparado a um modelo de médias de caselas**, que estima uma média independente para cada nível observado de X, sem impor uma forma funcional específica.
Nesse caso, o modelo de médias é o modelo completo, e a função não linear corresponde

ao modelo reduzido. A comparação pode ser realizada por meio de um teste F, utilizando a variação entre as médias ajustadas e a variabilidade das observações dentro de cada nível de X. A sobreposição de intervalos de confiança pode auxiliar na avaliação gráfica, mas não substitui o teste formal. Maiores detalhes, e exemplo de aplicação desse tipo de situação, podem sem visto em Zeviani et al. (2013).

8 Considerações finais

O ajuste de modelos de regressão não linear envolve etapas que vão além da estimação dos parâmetros. Desde a escolha da forma funcional e dos valores iniciais até a avaliação da qualidade do ajuste, cada etapa contribui para a construção de um modelo que seja estatisticamente consistente e coerente com o comportamento do fenômeno estudado. A Tabela 6 sintetiza as principais etapas discutidas neste e-book.

Tabela 6: Etapas do ajuste de modelos de regressão não linear.

Etapa	Objetivo
Especificação da forma funcional	Definir uma função que represente a relação entre a resposta e as variáveis explicativas.
Definição dos valores iniciais	Fornecer valores plausíveis para iniciar o processo iterativo de estimação.
Estimação dos parâmetros	Obter estimativas por meio da minimização da soma de quadrados dos resíduos.
Inferência	Quantificar a incerteza das estimativas e realizar testes e intervalos de confiança.
Diagnóstico do modelo	Avaliar a adequação do ajuste e verificar as suposições estabelecidas para os erros.
Comparação de modelos	Comparar modelos candidatos por meio de medidas de qualidade do ajuste.

Essas etapas não devem ser entendidas como uma sequência estritamente linear. Resultados obtidos durante o ajuste e o diagnóstico podem indicar a necessidade de revisar decisões anteriores, como alterar valores iniciais, reconsiderar a forma funcional ou testar modelos alternativos. Em todo o processo, a interpretação dos parâmetros e o conhecimento sobre o fenômeno devem ser considerados conjuntamente com os critérios estatísticos, garantindo que o modelo final seja não apenas bem ajustado, mas também significativo do ponto de vista prático.

Referências

BATES, D. M.; WATTS, D. G. Nonlinear regression analysis and its applications. New York: Wiley, 1988.

JAMES, G.; WITTEN, D.; HASTIE, T.; TIBSHIRANI, R. An introduction to statistical learning: with applications in R. New York: Springer, 2013.

MAZUCHELI, J.; ACHCAR, J. Algumas considerações em regressão não linear. Acta Scientiarum : Technology, v. 24, 2002. 10.4025/actascitechnol.v24i0.2551.

MICHAELIS, L.; MENTEN, M. Die kinetik der invertinwirkung. Biochemische zeiturg, v. 49, p. 333–369, 1913.

RITZ, C.; STREIBIG, J. C. Nonlinear regression with R. New York: Springer, 2008.

SEBER, G. A. F.; WILD, C. J. Nonlinear regression. New Jersey: John Wiley & Sons, Inc., Hoboken, 2003.

VENABLES, W.; RIPLEY, B. Modern applied statistics with S. Springer New York, 2013.

ZEVIANI, W.M.; RIBEIRO JÚNIOR, P.J.; BONAT, W.H. Modelos de regressão não linear. Campina Grande: RBRAS; SEAGRO, 2013. Apostila do 58° RBRAS e 15° SEAGRO. Disponível em: http://www.leg.ufpr.br/walmes/mrnl2013.